A BIT ABOUT DIGITAL

BILINGUAL EDITION · ENGLISH & KHMER

# គណិតវិទ្យាមូលដ្ឋាន សម្រាប់វិទ្យាសាស្ត្រទិន្នន័យ

# BASIC MATH FOR DATA SCIENCE

## WITH APPLICATIONS IN PYTHON

ព្រមទាំងការអនុវត្តជាមួយ Python

Linear Algebra | Calculus | Probability | Statistics | Regression

A BIT ABOUT DIGITAL · 2026

## គណិតវិទ្យាមូលដ្ឋានសម្រាប់វិទ្យាសាស្ត្រទិន្នន័យ

# BASIC MATH FOR DATA SCIENCE

## WITH APPLICATIONS IN PYTHON

A short bilingual textbook for students and new analysts. Every idea comes with a plain explanation, a formula, a worked Python example, and exercises.

សៀវភៅសិក្សាពីរភាសាខ្លីមួយ សម្រាប់និស្សិត និងអ្នកវិភាគទិន្នន័យថ្មី។ គំនិតនីមួយៗមានការពន្យល់ងាយយល់ រូបមន្ត ឧទាហរណ៍ Python ដែលដំណើរការពិត និងលំហាត់។

A BIT ABOUT DIGITAL

Innovation | Sharing | Open

**Basic Math for Data Science with Applications in Python**
First edition, October 2026
Published by A Bit About Digital

This book may be shared and printed for non-commercial teaching and self-study.

**Software used for every example.** Python 3.11, NumPy 2.4, pandas 3.0, SciPy 1.17, Matplotlib 3.10 and scikit-learn 1.8. All code listings in this book were run, and the outputs shown are the real outputs. Small differences can appear with other library versions.

**Data.** The study-hours, website and waiting-time datasets are synthetic. They were generated with fixed random seeds so that you can reproduce every number.

**Translation.** Each section gives the English text followed by a Khmer version. Technical terms keep the English word in brackets the first time they appear, so readers can search for them online.

**ការបកប្រែ។** ផ្នែកនីមួយៗមានអត្ថបទជាភាសាអង់គ្លេស ហើយបន្តដោយកំណែជាភាសាខ្មែរ។ ពាក្យបច្ចេកទេសរក្សាពាក្យអង់គ្លេសក្នុងវង់ក្រចកនៅពេលលេចឡើងលើកដំបូង ដើម្បីងាយស្រួលស្វែងរកតាមអ៊ីនធឺណិត។

# PREFACE

## អារម្ភកថា

Data science turns numbers into decisions. Behind every chart, model and prediction there are a few mathematical ideas that appear again and again: vectors and matrices to hold data, derivatives to improve models, probability to handle uncertainty, and statistics to learn from samples. You do not need to be a mathematician to use them well, but you do need to understand what they mean.

> វិទ្យាសាស្ត្រទិន្នន័យបំប្លែងលេខឱ្យទៅជាការសម្រេចចិត្ត។ នៅពីក្រោយក្រាហ្វិក ម៉ូដែល និងការព្យាករណ៍នីមួយៗ មានគំនិតគណិតវិទ្យាមួយចំនួនដែលលេចឡើងម្តងហើយម្តងទៀត៖ វ៉ិចទ័រ និងម៉ាទ្រីសសម្រាប់ផ្ទុកទិន្នន័យ ដេរីវេ សម្រាប់កែលម្អម៉ូដែល ប្រូបាបសម្រាប់ដោះស្រាយភាពមិនប្រាកដប្រជា និងស្ថិតិសម្រាប់រៀនពីសំណាក។ អ្នកមិនចាំបាច់ជាគណិតវិទូដើម្បីប្រើវាបានល្អទេ ប៉ុន្តែអ្នកត្រូវយល់ពីអត្ថន័យរបស់វា។

This book teaches exactly that core, in English and Khmer side by side. Each chapter follows the same rhythm: the idea in plain words, the formula, a small worked example by hand, then the same idea in Python. Chapter 7 brings everything together by building a linear regression model from scratch and checking it against scikit-learn.

> សៀវភៅនេះបង្រៀនចំណុចស្នូលទាំងនោះ ជាភាសាអង់គ្លេស និងខ្មែរ ទន្ទឹមគ្នា។ ជំពូកនីមួយៗមានលំនាំដូចគ្នា៖ គំនិតជាពាក្យសាមញ្ញ រូបមន្ត ឧទាហរណ៍តូចមួយគណនាដោយដៃ ហើយបន្ទាប់មកគំនិតដដែលនោះជាមួយ Python។ ជំពូកទី ៧ ប្រមូលអ្វីៗទាំងអស់មកបង្កើតម៉ូដែលតំរែតំរង់លីនេអ៊ែរ (linear regression) ពីដំបូង ហើយផ្ទៀងផ្ទាត់វាជាមួយ scikit-learn។

### How to use this book

របៀបប្រើសៀវភៅនេះ

- `DEFINITION` boxes give the exact meaning of a term.
- `KEY FORMULA` boxes hold the formulas worth remembering.
- `IN DATA SCIENCE` boxes show where the idea is used in real work.
- Code listings are followed by their **output**. Type them yourself in Jupyter or Google Colab; Appendix B shows how to set up Python.
- Numbers in square brackets, such as [1], point to the References at the end of the book, where you can read further.

> ប្រអប់ **និយមន័យ** ផ្តល់អត្ថន័យច្បាស់លាស់នៃពាក្យ។ ប្រអប់ **រូបមន្តសំខាន់** ផ្ទុករូបមន្តដែលគួរចងចាំ។ ប្រអប់ **ក្នុងវិទ្យាសាស្ត្រទិន្នន័យ** បង្ហាញកន្លែងដែលគំនិតនោះត្រូវបានប្រើក្នុងការងារពិត។ កូដនីមួយៗមានលទ្ធផល

> (output) នៅខាងក្រោម។ សូមវាយកូដដោយខ្លួនឯងក្នុង Jupyter ឬ Google Colab។ លេខក្នុងតង្កៀបការ៉េ ដូចជា [1] សំដៅទៅឯកសារយោងនៅចុងសៀវភៅ។

# CONTENTS

## មាតិកា


1 **Notation, Functions and Logarithms**
សញ្ញាណ អនុគមន៍ និងលោការីត ..... 8
1.1 Why math for data science? ..... 8
1.2 Sets and common symbols ..... 9
1.3 Summation notation ..... 9
1.4 Functions ..... 10
1.5 Exponents and logarithms ..... 11

2 **Linear Algebra: Vectors and Matrices**
ពីជគណិតលីនេអ៊ែរ៖ វ៉ិចទ័រ និងម៉ាទ្រីស ..... 14
2.1 Vectors ..... 14
2.2 Dot product, length and angle ..... 15
2.3 Matrices and matrix multiplication ..... 17
2.4 Transpose, identity and inverse ..... 18
2.5 Solving systems of linear equations ..... 19

3 **Calculus for Optimisation**
កាល់គុលសម្រាប់ការធ្វើឱ្យប្រសើរបំផុត ..... 22
3.1 The derivative ..... 22
3.2 Rules of differentiation ..... 23
3.3 Partial derivatives and the gradient ..... 24
3.4 Gradient descent ..... 25

4 **Probability**
ប្រូបាប ..... 28
4.1 Events and the rules of probability ..... 28
4.2 Conditional probability and Bayes' theorem ..... 29
4.3 Random variables, expectation and variance ..... 30
4.4 Two important distributions ..... 31

5 **Descriptive Statistics**
ស្ថិតិពិពណ៌នា ..... 35
5.1 Measures of centre ..... 35
5.2 Measures of spread ..... 36
5.3 Covariance and correlation ..... 38

6 **Inferential Statistics**
ស្ថិតិសន្និដ្ឋាន ..... 41
6.1 Populations and samples ..... 41

6.2 The Central Limit Theorem ..... 42
6.3 Confidence intervals ..... 43
6.4 Hypothesis testing and p-values ..... 44

**Project: Linear Regression from Scratch**
7 គម្រោង៖ តំរែតំរង់លីនេអ៊ែរពីដំបូង ..... **47**
7.1 The model ..... 47
7.2 Measuring error: the loss function ..... 48
7.3 Method 1: the normal equation ..... 48
7.4 Method 2: gradient descent ..... 49
7.5 Evaluating the model ..... 51

**Answers to Exercises**
A ចម្លើយលំហាត់ ..... **54**

**Python Setup and Cheat Sheet**
B ការដំឡើង Python និងសន្លឹកជំនួយ ..... **56**

**English–Khmer Glossary**
C សទ្ទានុក្រម អង់គ្លេស–ខ្មែរ ..... **57**

**References**
ឯកសារយោង ..... **58**

CHAPTER 1

# NOTATION, FUNCTIONS AND LOGARITHMS

## សញ្ញាណ អនុគមន៍ និងលោការីត

IN THIS CHAPTER ក្នុងជំពូកនេះ

- Read the math symbols used in data science papers and documentation
- Use summation notation to describe totals and averages
- Understand functions, exponents and logarithms, and why logs tame skewed data
- អាននិមិត្តសញ្ញាគណិតវិទ្យាដែលប្រើក្នុងឯកសារវិទ្យាសាស្ត្រទិន្នន័យ
- ប្រើសញ្ញាណផលបូកដើម្បីពិពណ៌នាផលបូកសរុប និងមធ្យមភាគ
- យល់ពីអនុគមន៍ ស្វ័យគុណ និងលោការីត ព្រមទាំងហេតុអ្វីលោការីតជួយទិន្នន័យដែលលម្អៀង

### 1.1 Why math for data science?

ហេតុអ្វីត្រូវការគណិតវិទ្យា?

A dataset is a table of numbers. Each row is an observation, such as a customer or a loan, and each column is a feature, such as age or income. Almost everything we do with that table is mathematics: we summarise columns with averages, measure how two columns move together, fit a line through points, and estimate how sure we are about the result. Libraries like NumPy and scikit-learn do the arithmetic, but you choose the method and you explain the result. Understanding the math is what lets you make good choices [1].

> សំណុំទិន្នន័យ (dataset) គឺជាតារាងលេខ។ ជួរដេកនីមួយៗជាការសង្កេតមួយ ដូចជាអតិថិជន ឬកម្ចីមួយ ហើយជួរឈរនីមួយៗជាលក្ខណៈ (feature) ដូចជាអាយុ ឬប្រាក់ចំណូល។ ស្ទើរតែគ្រប់យ៉ាងដែលយើងធ្វើជាមួយតារាងនោះគឺជាគណិតវិទ្យា៖ យើងសង្ខេបជួរឈរដោយមធ្យមភាគ វាស់ពីរបៀបដែលជួរឈរពីរប្រែប្រួលជាមួយគ្នា គូសបន្ទាត់កាត់តាមចំណុច និងប៉ាន់ស្មានថាយើងព្រាកដប៉ុណ្ណាលើលទ្ធផល។ បណ្ណាល័យដូចជា NumPy និង scikit-learn ធ្វើការគណនា ប៉ុន្តែអ្នកជាអ្នកជ្រើសរើសវិធីសាស្ត្រ និងពន្យល់លទ្ធផល។

## 1.2 Sets and common symbols

### សំណុំ និងនិមិត្តសញ្ញាទូទៅ

A **set** is a collection of distinct objects. We write sets with curly brackets, for example $A = \{1, 2, 3\}$. The symbol $\in$ means "is an element of", so $2 \in A$. Some sets of numbers have standard names: $\mathbb{N}$ for natural numbers, $\mathbb{Z}$ for integers and $\mathbb{R}$ for real numbers. When a data point has $n$ features, we say it lives in $\mathbb{R}^n$.

> **សំណុំ (set)** គឺជាបណ្តុំនៃវត្ថុខុសៗគ្នា។ យើងសរសេរសំណុំដោយតង្កៀបរួញ ឧទាហរណ៍ $A = \{1, 2, 3\}$។ និមិត្តសញ្ញា $\in$ មានន័យថា «ជាធាតុនៃ» ដូច្នេះ $2 \in A$។ សំណុំលេខមួយចំនួនមានឈ្មោះស្តង់ដារ៖ $\mathbb{N}$ សម្រាប់ចំនួនគត់ធម្មជាតិ $\mathbb{Z}$ សម្រាប់ចំនួនគត់វិឡាទីប និង $\mathbb{R}$ សម្រាប់ចំនួនពិត។ នៅពេលចំណុចទិន្នន័យមួយមាន $n$ លក្ខណៈ យើងនិយាយថាវាស្ថិតនៅក្នុង $\mathbb{R}^n$។

| Symbol | Meaning | អត្ថន័យ |
|---|---|---|
| $x_i$ | the $i$-th value of $x$ | តម្លៃទី $i$ នៃ $x$ |
| $\sum$ | sum (add up) | ផលបូក |
| $\prod$ | product (multiply together) | ផលគុណ |
| $\bar{x}$ | sample mean of $x$ | មធ្យមភាគសំណាកនៃ $x$ |
| $\hat{y}$ | a predicted (estimated) value | តម្លៃព្យាករណ៍ ឬប៉ាន់ស្មាន |
| $\approx$ | approximately equal | ប្រហែលស្មើ |
| $f : \mathbb{R} \to \mathbb{R}$ | a function from reals to reals | អនុគមន៍ពីចំនួនពិតទៅចំនួនពិត |

## 1.3 Summation notation

### សញ្ញាណផលបូក

Data science formulas constantly add things up. Instead of writing $x_1 + x_2 + \cdots + x_n$, we use the Greek capital sigma:

$$\sum_{i=1}^{n} x_i = x_1 + x_2 + \cdots + x_n.$$

Read it as "the sum of $x_i$ for $i$ from 1 to $n$". With this notation the **mean** (average) of $n$ values is short and precise:

KEY FORMULA  រូបមន្តសំខាន់

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i$$

*Worked example.* For $x = (4, 8, 15, 16, 23, 42)$ we have $n = 6$, $\sum x_i = 108$ and $\bar{x} = 108/6 = 18$. Two useful rules: constants move outside the sum, $\sum c\,x_i = c\sum x_i$, and sums split, $\sum(x_i + y_i) = \sum x_i + \sum y_i$.

រូបមន្តវិទ្យាសាស្ត្រទិន្នន័យតែងតែបូកបញ្ចូលគ្នា។ ជំនួសឱ្យការសរសេរ $x_1 + x_2 + \cdots + x_n$ យើងប្រើអក្សរក្រិក «ស៊ីក្ម» ធំ $\sum$។ អានថា «ផលបូកនៃ $x_i$ ចាប់ពី $i = 1$ ដល់ $n$»។ ដោយប្រើសញ្ញាណនេះ **មធ្យមភាគ (mean)** នៃគំរូ $n$ គឺ $\bar{x} = \frac{1}{n}\sum x_i$។ ឧទាហរណ៍៖ សម្រាប់ $x = (4, 8, 15, 16, 23, 42)$ យើងមាន $n = 6$ ផលបូក 108 ហើយ $\bar{x} = 18$។ ច្បាប់មានប្រយោជន៍ពីរ៖ ចំនួនថេរអាចយកចេញក្រៅផលបូកបាន ហើយផលបូកនៃផលបូកអាចបំបែកបាន។

PYTHON  LISTING 1.1

```python
import numpy as np

x = np.array([4, 8, 15, 16, 23, 42])

total = np.sum(x)          # Σ x_i
mean = total / len(x)      # (1/n) Σ x_i
squares = np.sum(x ** 2)   # Σ x_i²

print("sum     =", total)
print("mean    =", mean)
print("sum x^2 =", squares)
```

OUTPUT · លទ្ធផល

```
sum     = 108
mean    = 18.0
sum x^2 = 2854
```

## 1.4 Functions

### អនុគមន៍

DEFINITION  និយមន័យ

A **function** $f$ assigns exactly one output $f(x)$ to each input $x$. A machine learning model is a function: it takes features $x$ and returns a prediction $\hat{y} = f(x)$.

**អនុគមន៍ (function)** $f$ ផ្តល់លទ្ធផលតែមួយគត់ $f(x)$ ទៅឱ្យធាតុចូល $x$ នីមួយៗ។ ម៉ូដែលរៀនម៉ាស៊ីនក៏ជាអនុគមន៍ដែរ៖ វាទទួលលក្ខណៈ $x$ ហើយផ្តល់ការព្យាករណ៍ $\hat{y} = f(x)$។

Three function shapes appear everywhere. A **linear** function $f(x) = mx + b$ is a straight line with slope $m$ and intercept $b$. A **quadratic** function such as $f(x) = x^2$ is a U-shaped curve; squared errors in Chapter 7 have this shape. An **exponential** function such as $g(x) = e^x$ grows faster and faster, where $e \approx 2.71828$ is Euler's number [2]. Figure 1.1 compares them with the logarithm.

រាងអនុគមន៍បីប្រភេទលេចឡើងគ្រប់ទីកន្លែង។ អនុគមន៍ **លីនេអ៊ែរ** $f(x) = mx + b$ ជាបន្ទាត់ត្រង់ដែលមានមេគុណប្រាប់ទិស (slope) $m$ និងចំណុចប្រសព្វ (intercept) $b$។ អនុគមន៍ **ដឺក្រេទីពីរ** ដូចជា $f(x) = x^2$ ជាខ្សែកោងរាងអក្សរ U ដែលកំហុសការ៉េក្នុងជំពូកទី ៧ មានរាងបែបនេះ។ អនុគមន៍ **អិចស្ប៉ូណង់ស្យែល** ដូចជា $g(x) = e^x$ កើនឡើងកាន់តែលឿន ដែល $e \approx 2.71828$ ជាចំនួនអយល័រ។

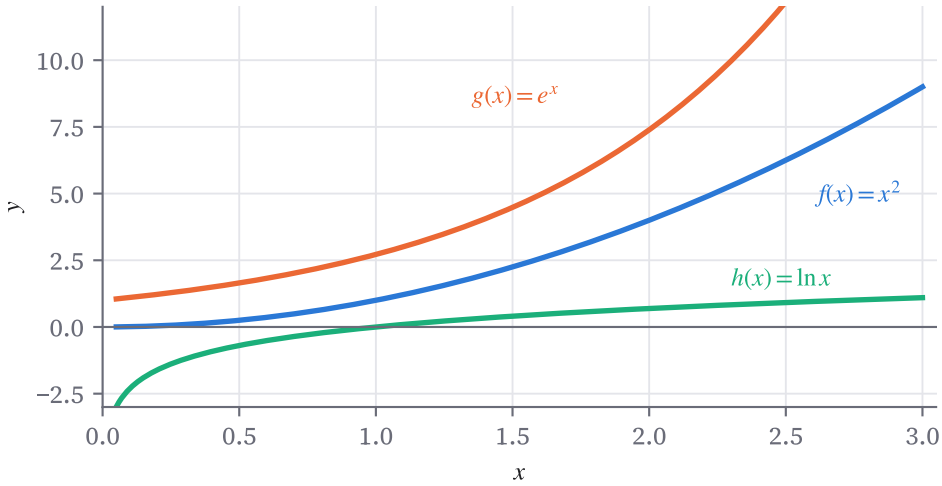



Figure 1.1 — A quadratic, an exponential and a logarithm. The logarithm grows very slowly.
រូបទី ១.១ — អនុគមន៍ដឺក្រេទីពីរ អិចស្ប៉ូណង់ស្យែល និងលោការីត។ លោការីតកើនយឺតណាស់។

## 1.5 Exponents and logarithms

### ស្វ័យគុណ និងលោការីត

An exponent tells us how many times to multiply: $2^3 = 8$. The **logarithm** answers the reverse question: to what power must we raise the base to get a number? So $\log_2 8 = 3$ and $\log_{10} 1000 = 3$. The natural logarithm $\ln x$ uses base $e$. Logs and exponentials undo each other: $\ln(e^x) = x$ and $e^{\ln x} = x$.

KEY FORMULAS រូបមន្តសំខាន់

$$\log(ab) = \log a + \log b \qquad \log\left(\frac{a}{b}\right) = \log a - \log b \qquad \log(a^k) = k \log a$$

ស្វ័យគុណប្រាប់យើងថាត្រូវគុណប៉ុន្មានដង៖ $2^3 = 8$។ **លោការីត (logarithm)** ឆ្លើយសំណួរផ្ទុយ៖ តើត្រូវលើកគោលទៅស្វ័យគុណប៉ុន្មាន ដើម្បីបានចំនួនមួយ? ដូច្នេះ $\log_2 8 = 3$ និង $\log_{10} 1000 = 3$។ លោការីតធម្មជាតិ $\ln x$ ប្រើគោល $e$។ លោការីត និងអិចស្ប៉ូណង់ស្យែលលុបបំបាត់គ្នាទៅវិញទៅមក។ ច្បាប់ខាងលើបួរផលគុណទៅជាផលបូក ដែលងាយស្រួលគណនា។

IN DATA SCIENCE ក្នុងវិទ្យាសាស្ត្រទិន្នន័យ

Incomes, prices and website visits are usually **right-skewed**: most values are small and a few are huge. Taking $\log_{10}$ turns 300 into 2.48 and 40,000 into 4.60, so one extreme value no longer dominates a chart or a model. Logarithms also appear in the loss function of logistic regression and in information theory [3].

ប្រាក់ចំណូល តម្លៃទំនិញ និងចំនួនអ្នកចូលមើលគេហទំព័រ ជាធម្មតា **លម្អៀងទៅស្តាំ (right-skewed)**៖ តម្លៃភាគច្រើនតូច ហើយមួយចំនួនតិចធំខ្លាំង។ ការយក $\log_{10}$ បួរ 300 ទៅជា 2.48 និង 40,000 ទៅជា 4.60 ដូច្នេះតម្លៃជ្រុលមួយលែងគ្របដណ្តប់ក្រាហ្វិក ឬម៉ូដែល។

PYTHON LISTING 1.2

```python
import numpy as np

incomes = np.array([300, 450, 800, 1_200, 5_000, 40_000])  # USD / month

log_inc = np.log10(incomes)
print(np.round(log_inc, 2))

# exp and log undo each other
print(np.exp(np.log(7.5)))

# compound growth: 1,000 at 5% per year for 10 years
print(round(1000 * (1 + 0.05) ** 10, 2))
```

OUTPUT · លទ្ធផល

```
[2.48 2.65 2.9  3.08 3.7  4.6 ]
7.499999999999999
1628.89
```

The last line uses the compound growth formula $A = P(1+r)^t$: 1,000 invested at 5% per year grows to 1,628.89 after 10 years. Notice also that `np.exp(np.log(7.5))` prints `7.499999999999999`. Computers store decimals with tiny rounding errors, so compare floating-point numbers with a tolerance, for example `np.isclose`, never with `==`.

បន្ទាត់ចុងក្រោយប្រើរូបមន្តកំណើនសមាសធាតុ $A = P(1+r)^t$៖ ប្រាក់ 1,000 វិនិយោគក្នុងអត្រា 5% ក្នុងមួយឆ្នាំ កើនដល់ 1,628.89 ក្រោយ 10 ឆ្នាំ។ សូមកត់សម្គាល់ថា `np.exp(np.log(7.5))` បង្ហាញ

> `7.499999999999999` ។ កុំព្យូទ័ររក្សាទុកលេខទសភាគជាមួយកំហុសបង្គត់តូចៗ ដូច្នេះត្រូវប្រៀបធៀបលេខទសភាគដោយប្រើ `np.isclose` មិនមែន `==` ទេ។

---

## Exercises 1

លំហាត់ ១

1. Write $3 + 6 + 9 + 12 + 15$ using summation notation.
   សរសេរផលបូកនេះដោយប្រើសញ្ញាណ $\sum$។
2. Compute $\bar{x}$ for $x = (2, 5, 5, 8)$ by hand, then check with NumPy.
   គណនាមធ្យមភាគដោយដៃ ហើយផ្ទៀងផ្ទាត់ជាមួយ NumPy។
3. Simplify $\log_{10}(1000) + \log_{10}(0.01)$.
   សម្រួលកន្សោមនេះ។
4. A city has 2 million people and grows 3% per year. Estimate the population after 15 years.
   ប៉ាន់ស្មានចំនួនប្រជាជនក្រោយ ១៥ ឆ្នាំ។
5. Why might a data scientist apply log to a column of house prices before plotting it?
   ហេតុអ្វីអ្នកវិទ្យាសាស្ត្រទិន្នន័យអាចយក log នៃតម្លៃផ្ទះ មុនពេលគូសក្រាហ្វិក?

CHAPTER 2

# LINEAR ALGEBRA: VECTORS AND MATRICES

## ពីជគណិតលីនេអ៊ែរ៖ វ៉ិចទ័រ និងម៉ាទ្រីស

IN THIS CHAPTER ក្នុងជំពូកនេះ

- Represent data points as vectors and datasets as matrices
- Compute dot products, lengths and cosine similarity
- Multiply matrices and solve a system of linear equations with NumPy
- តំណាងចំណុចទិន្នន័យជាវ៉ិចទ័រ និងសំណុំទិន្នន័យជាម៉ាទ្រីស
- គណនាផលគុណស្កាលែ ប្រវែង និងភាពស្រដៀងកូស៊ីនុស
- គុណម៉ាទ្រីស និងដោះស្រាយប្រព័ន្ធសមីការលីនេអ៊ែរជាមួយ NumPy

## 2.1 Vectors

### វ៉ិចទ័រ

DEFINITION និយមន័យ

A **vector** is an ordered list of numbers, $\mathbf{x} = (x_1, x_2, \dots, x_n) \in \mathbb{R}^n$. Geometrically it is an arrow from the origin to a point in $n$-dimensional space.

**វ៉ិចទ័រ (vector)** គឺជាបញ្ជីលេខដែលមានលំដាប់ $\mathbf{x} = (x_1, x_2, \dots, x_n) \in \mathbb{R}^n$។ តាមធរណីមាត្រ វាជាព្រួញចេញពីគល់អ័ក្សទៅចំណុចមួយក្នុងលំហ $n$ វិមាត្រ។

In data science, one row of a table is a vector. A student with 6 study hours, 85% attendance and age 20 is the vector $(6, 85, 20) \in \mathbb{R}^3$. We add two vectors element by element, and we multiply a vector by a number (a **scalar**) by multiplying every element:

$$\mathbf{a} + \mathbf{b} = (a_1 + b_1, \dots, a_n + b_n), \qquad c\,\mathbf{a} = (c\,a_1, \dots, c\,a_n).$$

ក្នុងវិទ្យាសាស្ត្រទិន្នន័យ ជួរដេកមួយនៃតារាងគឺជាវ៉ិចទ័រមួយ។ និស្សិតម្នាក់ដែលរៀន ៦ ម៉ោង មានវត្តមាន 85% និងអាយុ ២០ ឆ្នាំ គឺជាវ៉ិចទ័រ $(6, 85, 20) \in \mathbb{R}^3$។ យើងបូកវ៉ិចទ័រពីរដោយបូកធាតុនីមួយៗតាមទីតាំង ហើយយើងគុណវ៉ិចទ័រនឹងចំនួនមួយ (ហៅថា **ស្កាលែ (scalar)**) ដោយគុណធាតុទាំងអស់។ រូបទី ២.១ បង្ហាញការបូកវ៉ិចទ័រជាទម្រង់ប្រលេឡូក្រាម។

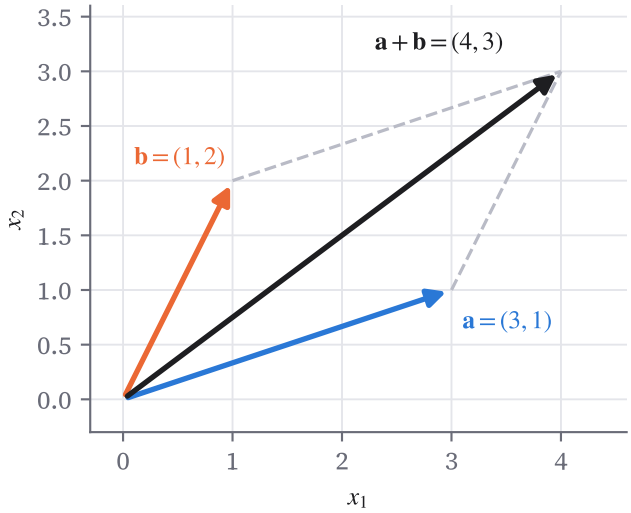



Figure 2.1 — Vector addition: place b at the tip of a. The sum is the diagonal of the parallelogram.
រូបទី ២.១ — ការបូកវ៉ិចទ័រ៖ ដាក់ b នៅចុង a។ ផលបូកគឺអង្កត់ទ្រូងនៃប្រលេឡូក្រាម។

## 2.2 Dot product, length and angle

### ផលគុណស្កាលែ ប្រវែង និងមុំ

The **dot product** multiplies matching elements and adds the results. The **norm** (length) of a vector comes from the Pythagorean theorem. Together they give the angle $\theta$ between two vectors [4]:

KEY FORMULAS  រូបមន្តសំខាន់

$$\mathbf{a}\cdot\mathbf{b}=\sum_{i=1}^{n}a_i b_i, \qquad \|\mathbf{a}\|=\sqrt{\mathbf{a}\cdot\mathbf{a}}, \qquad \cos\theta=\frac{\mathbf{a}\cdot\mathbf{b}}{\|\mathbf{a}\|\,\|\mathbf{b}\|}$$

*Worked example.* Let $\mathbf{a}=(2,1,3)$ and $\mathbf{b}=(1,4,0)$. Then $\mathbf{a}\cdot\mathbf{b}=2+4+0=6$, $\|\mathbf{a}\|=\sqrt{4+1+9}=\sqrt{14}\approx 3.742$ and $\|\mathbf{b}\|=\sqrt{17}\approx 4.123$, so $\cos\theta=6/(3.742\times 4.123)\approx 0.389$.

**ផលគុណស្កាលែ (dot product)** គុណធាតុដែលត្រូវគ្នា ហើយបូកលទ្ធផល។ **ណម (norm)** ឬប្រវែងនៃវ៉ិចទ័រ បានមកពីទ្រឹស្តីបទពីតាគ័រ។ ទាំងពីររួមគ្នាផ្តល់មុំ $\theta$ រវាងវ៉ិចទ័រពីរ។ ឧទាហរណ៍៖ $\mathbf{a}\cdot\mathbf{b}=6$ និង $\cos\theta\approx 0.389$។ បើ $\cos\theta=1$ វ៉ិចទ័រចង្អុលទិសដូចគ្នា បើ $0$ វាកែងគ្នា (មិនទាក់ទងគ្នា)។

PYTHON LISTING 2.1

```python
import numpy as np

a = np.array([2, 1, 3])
b = np.array([1, 4, 0])

print("a + b   =", a + b)
print("3a      =", 3 * a)
print("a . b   =", a @ b)              # dot product
print("||a||   =", round(np.linalg.norm(a), 4))

cos = (a @ b) / (np.linalg.norm(a) * np.linalg.norm(b))
print("cos(θ)  =", round(cos, 4))
```

OUTPUT · លទ្ធផល

```
a + b   = [3 5 3]
3a      = [6 3 9]
a . b   = 6
||a||   = 3.7417
cos(θ)  = 0.3889
```

IN DATA SCIENCE ក្នុងវិទ្យាសាស្ត្រទិន្នន័យ

**Cosine similarity** measures how alike two items are, regardless of size. Search engines and recommendation systems turn documents into vectors of word counts (or embeddings) and rank them by cosine similarity. A value near 1 means "very similar", 0 means "nothing in common".

**ភាពស្រដៀងកូស៊ីនុស (cosine similarity)** វាស់ថាវត្ថុពីរស្រដៀងគ្នាប៉ុណ្ណា ដោយមិនគិតពីទំហំ។ ម៉ាស៊ីនស្វែងរក និងប្រព័ន្ធណែនាំ បំប្លែងឯកសារទៅជាវ៉ិចទ័រនៃចំនួនពាក្យ (ឬ embedding) ហើយតម្រៀបតាមភាពស្រដៀងកូស៊ីនុស។

PYTHON LISTING 2.2

```python
import numpy as np

# word counts for: [data, python, math, food, travel]
docs = {
    "A: data science intro": np.array([5, 3, 4, 0, 0]),
    "B: python for analysts": np.array([4, 6, 1, 0, 0]),
    "C: street food guide":   np.array([0, 0, 0, 7, 3]),
}

def cosine(u, v):
    return u @ v / (np.linalg.norm(u) * np.linalg.norm(v))

names = list(docs)
for i in range(len(names)):
    for j in range(i + 1, len(names)):
        s = cosine(docs[names[i]], docs[names[j]])
        print(f"{names[i][:1]} vs {names[j][:1]}: {s:.3f}")
```

OUTPUT · លទ្ធផល

```
A vs B: 0.816
A vs C: 0.000
B vs C: 0.000
```

Documents A and B share words such as "data" and "python", so their similarity is 0.816. Document C is about food and travel and shares no words with them, so its similarity is 0.

ឯកសារ A និង B មានពាក្យរួមគ្នាដូចជា "data" និង "python" ដូច្នេះភាពស្រដៀងគឺ 0.816។ ឯកសារ C និយាយអំពីម្ហូប និងការធ្វើដំណើរ ដោយគ្មានពាក្យរួម ដូច្នេះភាពស្រដៀងគឺ 0។

## 2.3 Matrices and matrix multiplication

### ម៉ាទ្រីស និងការគុណម៉ាទ្រីស

A **matrix** is a rectangular table of numbers with $m$ rows and $n$ columns, written $A \in \mathbb{R}^{m \times n}$. A whole dataset is a matrix: $m$ observations (rows) by $n$ features (columns). The entry in row $i$ and column $j$ is $a_{ij}$.

To multiply $A$ ($m \times n$) by $B$ ($n \times p$), each entry of the result is the dot product of a row of $A$ with a column of $B$. The inner sizes must match, and the result is $m \times p$:

KEY FORMULA រូបមន្តសំខាន់

$$(AB)_{ij} = \sum_{k=1}^{n} a_{ik}\, b_{kj}$$

*Worked example.* With $A = \begin{pmatrix} 2 & 1 \\ 1 & 3 \end{pmatrix}$ and $B = \begin{pmatrix} 1 & 0 \\ 4 & 2 \end{pmatrix}$, the top-left entry of $AB$ is $2 \cdot 1 + 1 \cdot 4 = 6$. Doing all four entries gives $AB = \begin{pmatrix} 6 & 2 \\ 13 & 6 \end{pmatrix}$. In general $AB \neq BA$: the order matters.

**ម៉ាទ្រីស (matrix)** គឺជាតារាងលេខរាងចតុកោណកែងដែលមាន $m$ ជួរដេក និង $n$ ជួរឈរ សរសេរ $A \in \mathbb{R}^{m \times n}$។ សំណុំទិន្នន័យទាំងមូលគឺជាម៉ាទ្រីស៖ $m$ ការសង្កេត គុណនឹង $n$ លក្ខណៈ។

ដើម្បីគុណ $A$ $(m \times n)$ នឹង $B$ $(n \times p)$ ធាតុនីមួយៗនៃលទ្ធផល គឺជាផលគុណស្កាលែរនៃជួរដេកមួយរបស់ $A$ ជាមួយជួរឈរមួយរបស់ $B$។ ទំហំខាងក្នុងត្រូវតែស្មើគ្នា។ ជាទូទៅ $AB \neq BA$ មានន័យថាលំដាប់សំខាន់ណាស់។

## 2.4 Transpose, identity and inverse

### ម៉ាទ្រីសឆ្លាស់ ឯកតា និងច្រាស

The **transpose** $A^\top$ flips a matrix over its diagonal, so rows become columns. The **identity matrix** $I$ has 1s on the diagonal and 0s elsewhere; it acts like the number 1, because $AI = IA = A$. A square matrix $A$ has an **inverse** $A^{-1}$ if $AA^{-1} = I$. For a $2 \times 2$ matrix:

$$\begin{pmatrix} a & b \\ c & d \end{pmatrix}^{-1} = \frac{1}{ad - bc} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}, \qquad \text{if } ad - bc \neq 0.$$

The number $ad - bc$ is the **determinant**. If it is 0, the matrix has no inverse; in data this happens when one feature is an exact copy or combination of others.

**ម៉ាទ្រីសឆ្លាស់ (transpose)** $A^\top$ ត្រឡប់ម៉ាទ្រីសតាមអង្កត់ទ្រូង ដូច្នេះជួរដេកក្លាយជាជួរឈរ។ **ម៉ាទ្រីសឯកតា (identity)** $I$ មានលេខ 1 លើអង្កត់ទ្រូង និង 0 នៅកន្លែងផ្សេង វាធ្វើតួនាទីដូចលេខ 1។ ម៉ាទ្រីសការ៉េ $A$ មាន **ម៉ាទ្រីសច្រាស (inverse)** $A^{-1}$ បើ $AA^{-1} = I$។ ចំនួន $ad - bc$ ហៅថា **ដេទែមីណង់ (determinant)**។ បើវាស្មើ 0 ម៉ាទ្រីសគ្មានច្រាសទេ ដែលកើតឡើងនៅពេលលក្ខណៈមួយជាការចម្លង ឬបន្សំនៃលក្ខណៈផ្សេងទៀត។

PYTHON LISTING 2.3

```python
import numpy as np

A = np.array([[2, 1],
              [1, 3]])
B = np.array([[1, 0],
              [4, 2]])

print("A @ B =\n", A @ B)
print("B @ A =\n", B @ A)          # not the same!
print("A^T =\n", A.T)

A_inv = np.linalg.inv(A)
print("A^-1 =\n", np.round(A_inv, 3))
print("A @ A^-1 =\n", np.round(A @ A_inv, 10) + 0.0)
```

OUTPUT · លទ្ធផល

```
A @ B =
 [[ 6  2]
 [13  6]]
B @ A =
 [[ 2  1]
 [10 10]]
A^T =
 [[2 1]
 [1 3]]
A^-1 =
 [[ 0.6 -0.2]
 [-0.2  0.4]]
A @ A^-1 =
 [[1. 0.]
 [0. 1.]]
```

## 2.5 Solving systems of linear equations

### ការដោះស្រាយប្រព័ន្ធសមីការលីនេអ៊ែរ

Many problems reduce to $A\mathbf{x} = \mathbf{b}$: find the unknown vector $\mathbf{x}$. Suppose 2 notebooks and 1 pen cost 7,000 riel, and 1 notebook and 3 pens cost 6,000 riel. With $x_1$ = notebook price and $x_2$ = pen price:

$$\begin{pmatrix} 2 & 1 \\ 1 & 3 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 7000 \\ 6000 \end{pmatrix} \quad \Rightarrow \quad \mathbf{x} = A^{-1}\mathbf{b}.$$

In code, prefer `np.linalg.solve(A, b)` to computing the inverse. It is faster and more accurate on large or nearly singular matrices [5].

> បញ្ហាជាច្រើនអាចសរសេរជា $A\mathbf{x} = \mathbf{b}$៖ រកវ៉ិចទ័រមិនស្គាល់ $\mathbf{x}$។ ឧបមាថាសៀវភៅ ២ ក្បាល និងប៊ិច ១ ដើម តម្លៃ 7,000 រៀល ហើយសៀវភៅ ១ ក្បាល និងប៊ិច ៣ ដើម តម្លៃ 6,000 រៀល។ ក្នុងកូដ គួរប្រើ

`np.linalg.solve(A, b)` ជាជាងគណនាម៉ាទ្រីសច្រាស ព្រោះវារលឿន និងត្រឹមត្រូវជាង។

PYTHON LISTING 2.4

```python
import numpy as np

# 2 notebooks + 1 pen = 7,000 riel
# 1 notebook  + 3 pens = 6,000 riel
A = np.array([[2, 1],
              [1, 3]])
b = np.array([7000, 6000])

x = np.linalg.solve(A, b)
print("notebook =", x[0], "riel")
print("pen      =", x[1], "riel")
```

OUTPUT · លទ្ធផល

```
notebook = 3000.0 riel
pen      = 1000.0 riel
```

IN DATA SCIENCE ក្នុងវិទ្យាសាស្ត្រទិន្នន័យ

Linear regression in Chapter 7 is exactly a system of this kind: the best weights solve $X^\top X\,\mathbf{w} = X^\top \mathbf{y}$. Neural networks are long chains of matrix multiplications, which is why GPUs, built for fast matrix arithmetic, train them so quickly [3].

តំរែតំរង់លីនេអ៊ែរក្នុងជំពូកទី ៧ គឺជាប្រព័ន្ធប្រភេទនេះ៖ ទម្ងន់ល្អបំផុតដោះស្រាយ $X^\top X\,\mathbf{w} = X^\top \mathbf{y}$។ បណ្តាញសរសៃប្រសាទ (neural network) គឺជាខ្សែសង្វាក់វែងនៃការគុណម៉ាទ្រីស ដែលហេតុនេះ GPU អាចបង្វឹកវាបានលឿន។

## Exercises 2

លំហាត់ ២

1. Let $\mathbf{u} = (1, -2, 2)$. Find $\|\mathbf{u}\|$ and the unit vector $\mathbf{u}/\|\mathbf{u}\|$.
   រកប្រវែង និងវ៉ិចទ័រឯកតា។
2. Show that $(3, 4)$ and $(-4, 3)$ are perpendicular using the dot product.
   បង្ហាញថាវ៉ិចទ័រទាំងពីរកែងគ្នាដោយប្រើផលគុណស្កាលែ។
3. If $A$ is $3 \times 2$ and $B$ is $2 \times 4$, what is the size of $AB$? Is $BA$ defined?
   តើ $AB$ មានទំហំប៉ុន្មាន? តើ $BA$ អាចគណនាបានទេ?
4. Find the inverse of $\begin{pmatrix} 4 & 2 \\ 1 & 1 \end{pmatrix}$ by hand and check with NumPy.
   រកម៉ាទ្រីសច្រាសដោយដៃ ហើយផ្ទៀងផ្ទាត់ជាមួយ NumPy។

5. 3 coffees and 2 cakes cost 19,000 riel; 1 coffee and 1 cake cost 7,500 riel. Solve for each price with `np.linalg.solve`.
   ដោះស្រាយរកតម្លៃនីមួយៗ។

CHAPTER 3

# CALCULUS FOR OPTIMISATION

## កាល់គុលសម្រាប់ការធ្វើឱ្យប្រសើរបំផុត

IN THIS CHAPTER ក្នុងជំពូកនេះ

- Understand the derivative as a slope and a rate of change
- Apply the basic rules, partial derivatives and the gradient
- Use gradient descent to find the minimum of a function in Python
- យល់ពីដេរីវេជាមេគុណប្រាប់ទិស និងអត្រាបម្រែបម្រួល
- អនុវត្តច្បាប់មូលដ្ឋាន ដេរីវេដោយផ្នែក និងក្រាដ្យង់
- ប្រើការចុះតាមក្រាដ្យង់ ដើម្បីរកតម្លៃអប្បបរមានៃអនុគមន៍ជាមួយ Python

### 3.1 The derivative

ដេរីវេ

Training a model means making its error as small as possible. To do that we need to know: if I change a parameter a little, does the error go up or down, and how fast? That is exactly what a **derivative** tells us.

DEFINITION និយមន័យ

The derivative of $f$ at $x$ is the slope of the tangent line at that point:

$$f'(x) = \frac{df}{dx} = \lim_{h \to 0} \frac{f(x+h) - f(x)}{h}.$$

ដេរីវេ (derivative) នៃ $f$ ត្រង់ $x$ គឺជាមេគុណប្រាប់ទិសនៃបន្ទាត់ប៉ះ (tangent line) នៅចំណុចនោះ។ វាប្រាប់ថា $f$ ប្រែប្រួលលឿនប៉ុណ្ណា នៅពេល $x$ ប្រែប្រួលតិចតួច។

For $f(x) = x^2$, the slope at $x = 1$ is $f'(1) = 2$: near that point, increasing $x$ by a small amount $h$ increases $f$ by about $2h$ (Figure 3.1). Where the derivative is positive the function is rising; where it is negative the function is falling; where it is zero we may be at a minimum or maximum [2].

ការបង្វឹកម៉ូដែលមានន័យថា ធ្វើឱ្យកំហុសរបស់វាតូចបំផុតតាមដែលអាចធ្វើបាន។ ដើម្បីធ្វើដូច្នេះ យើងត្រូវដឹងថា៖ បើខ្ញុំប្តូរប៉ារ៉ាម៉ែត្របន្តិច តើកំហុសកើនឬថយ ហើយលឿនប៉ុណ្ណា? ដេរីវេប្រាប់យើងពីចំណុចនេះ។ សម្រាប់ $f(x) = x^2$ មេគុណប្រាប់ទិសត្រង់ $x = 1$ គឺ $f'(1) = 2$។ កន្លែងដែលដេរីវេវិជ្ជមាន អនុគមន៍កំពុងកើន កន្លែងដែលវាអវិជ្ជមាន អនុគមន៍កំពុងថយ ហើយកន្លែងដែលវាស្មើសូន្យ យើងអាចនៅត្រង់អប្បបរមា ឬអតិបរមា។

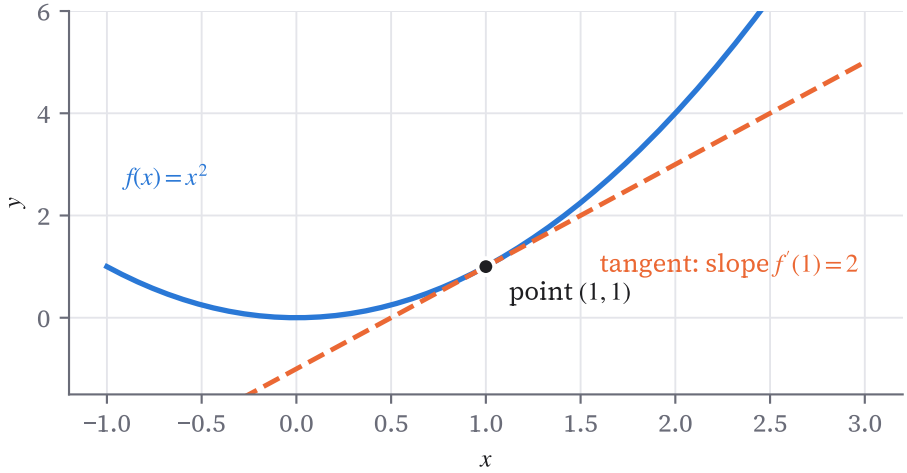



Figure 3.1 — The tangent line to f(x) = x² at x = 1 has slope 2.
រូបទី ៣.១ — បន្ទាត់ប៉ះនៃ f(x) = x² ត្រង់ x = 1 មានមេគុណប្រាប់ទិស 2។

## 3.2 Rules of differentiation

### ច្បាប់នៃការគណនាដេរីវេ

We rarely use the limit definition directly. A handful of rules covers almost every function in this book:

| Rule | Function | Derivative | ឈ្មោះ |
|---|---|---|---|
| Constant | $c$ | $0$ | ចំនួនថេរ |
| Power | $x^n$ | $n\,x^{n-1}$ | ស្វ័យគុណ |
| Exponential | $e^x$ | $e^x$ | អិចស្ប៉ូណង់ស្យែល |
| Logarithm | $\ln x$ | $1/x$ | លោការីត |
| Sum | $f + g$ | $f' + g'$ | ផលបូក |
| Product | $f\,g$ | $f'g + fg'$ | ផលគុណ |
| Chain | $f(g(x))$ | $f'(g(x))\,g'(x)$ | ខ្សែសង្វាក់ |

*Worked example.* For $f(x) = 3x^4 - 2x + 5$, the power, constant and sum rules give $f'(x) = 12x^3 - 2$. For $h(x) = (2x+1)^3$, the **chain rule** gives $h'(x) = 3(2x+1)^2 \cdot 2 = 6(2x+1)^2$. The chain rule is the engine of **backpropagation**, the algorithm that trains neural networks layer by layer [3].

> យើងកម្រប្រើនិយមន័យលើមីតដោយផ្ទាល់ណាស់។ ច្បាប់មួយចំនួនក្នុងតារាងគ្របដណ្តប់ស្ទើរតែគ្រប់អនុគមន៍ក្នុងសៀវភៅនេះ។ ឧទាហរណ៍៖ សម្រាប់ $f(x) = 3x^4 - 2x + 5$ យើងបាន $f'(x) = 12x^3 - 2$។ សម្រាប់ $h(x) = (2x+1)^3$ **វិធានខ្សែសង្វាក់ (chain rule)** ផ្តល់ $h'(x) = 6(2x+1)^2$។ វិធានខ្សែសង្វាក់ជាម៉ាស៊ីនរបស់ **backpropagation** ដែលជាក្បួនដោះស្រាយសម្រាប់បង្វឹកបណ្តាញសរសៃប្រសាទ។

A computer can approximate a derivative with a tiny step $h$, using the **central difference** $f'(x) \approx \dfrac{f(x+h) - f(x-h)}{2h}$. This is a good way to check a derivative you worked out by hand.

> កុំព្យូទ័រអាចប៉ាន់ស្មានដេរីវេដោយប្រើជំហានតូចបំផុត $h$ តាមរូបមន្ត **ផលដកកណ្តាល (central difference)**។ នេះជាវិធីល្អសម្រាប់ផ្ទៀងផ្ទាត់ដេរីវេដែលអ្នកគណនាដោយដៃ។

PYTHON LISTING 3.1

```python
def f(x):
    return x ** 2

def numerical_derivative(f, x, h=1e-5):
    return (f(x + h) - f(x - h)) / (2 * h)

for x in [-2, 0, 1, 3]:
    print(f"x = {x:>2}:  f'(x) ≈ {numerical_derivative(f, x):.4f}"
          f"   exact 2x = {2 * x}")
```

OUTPUT · លទ្ធផល

```
x = -2:  f'(x) ≈ -4.0000   exact 2x = -4
x =  0:  f'(x) ≈ 0.0000   exact 2x = 0
x =  1:  f'(x) ≈ 2.0000   exact 2x = 2
x =  3:  f'(x) ≈ 6.0000   exact 2x = 6
```

## 3.3 Partial derivatives and the gradient

### ដេរីវេដោយផ្នែក និងក្រាដ្យង់

Real models have many parameters. For a function of several variables, a **partial derivative** $\partial f / \partial w_j$ measures the slope in the direction of $w_j$ while all other variables are held fixed. Collecting all partial derivatives gives the **gradient**:

KEY FORMULA រូបមន្តសំខាន់

$$\nabla f(\mathbf{w}) = \left( \frac{\partial f}{\partial w_1}, \frac{\partial f}{\partial w_2}, \ldots, \frac{\partial f}{\partial w_n} \right)$$

The gradient is a vector that points in the direction of steepest increase. Its negative, $-\nabla f$, points downhill. *Example:* for $f(w_1, w_2) = w_1^2 + 3w_2^2$ we get $\partial f/\partial w_1 = 2w_1$ and $\partial f/\partial w_2 = 6w_2$, so $\nabla f(4, 2) = (8, 12)$.

ម៉ូដែលពិតមានប៉ារ៉ាម៉ែត្រច្រើន។ សម្រាប់អនុគមន៍ច្រើនអថេរ **ដេរីវេដោយផ្នែក (partial derivative)** $\partial f/\partial w_j$ វាស់មេគុណប្រាប់ទិសតាមទិស $w_j$ ខណៈអថេរផ្សេងទៀតត្រូវរក្សាថេរ។ ការប្រមូលដេរីវេដោយផ្នែកទាំងអស់ផ្តល់ **ក្រាដ្យង់ (gradient)** $\nabla f$។ ក្រាដ្យង់ជាវ៉ិចទ័រដែលចង្អុលទៅទិសកើនឡើងចោតបំផុត ហើយ $-\nabla f$ ចង្អុលចុះក្រោម។

## 3.4 Gradient descent

ការចុះតាមក្រាដ្យង់

Imagine standing on a hill in fog. You cannot see the valley, but you can feel the slope under your feet. Take a small step downhill, feel again, and repeat. This is **gradient descent**, the most widely used optimisation method in machine learning [6]:

KEY FORMULA រូបមន្តសំខាន់

$$\mathbf{w}_{\text{new}} = \mathbf{w}_{\text{old}} - \eta \, \nabla f(\mathbf{w}_{\text{old}})$$

The **learning rate** $\eta$ controls the step size. If it is too small, training is slow; if it is too large, the steps overshoot the valley and the values can explode. Values such as 0.1, 0.01 or 0.001 are common starting points.

ស្រមៃថាអ្នកឈរលើភ្នំក្នុងអ័ព្ទ។ អ្នកមើលមិនឃើញជ្រលង ប៉ុន្តែអាចមានអារម្មណ៍ពីជម្រាលក្រោមជើង។ ដើរមួយជំហានតូចចុះក្រោម មានអារម្មណ៍ម្តងទៀត ហើយធ្វើបែបនេះតទៅ។ នេះគឺ **ការចុះតាមក្រាដ្យង់ (gradient descent)** ដែលជាវិធីសាស្ត្របង្កើនប្រសិទ្ធភាពដែលប្រើច្រើនបំផុតក្នុងការរៀនម៉ាស៊ីន។ **អត្រារៀន (learning rate)** $\eta$ គ្រប់គ្រងទំហំជំហាន។ បើតូចពេក ការបង្វឹកយឺត បើធំពេក ជំហានរំលងជ្រលង ហើយតម្លៃអាចផ្ទុះឡើង។

PYTHON LISTING 3.2

```python
import numpy as np
np.set_printoptions(suppress=True)

def f(w):                       # f(w1, w2) = w1² + 3·w2²
    return w[0] ** 2 + 3 * w[1] ** 2

def grad_f(w):                  # ∇f = [2·w1, 6·w2]
    return np.array([2 * w[0], 6 * w[1]])

w = np.array([4.0, 2.0])        # starting point
lr = 0.1                        # learning rate η

for step in range(1, 31):
    w = w - lr * grad_f(w)
    if step in (1, 2, 5, 10, 30):
        print(f"step {step:>2}: w = {np.round(w, 4)}, f(w) = {f(w):.6f}")
```

OUTPUT · លទ្ធផល

```
step  1: w = [3.2 0.8], f(w) = 12.160000
step  2: w = [2.56 0.32], f(w) = 6.860800
step  5: w = [1.3107 0.0205], f(w) = 1.719245
step 10: w = [0.4295 0.0002], f(w) = 0.184468
step 30: w = [0.005 0.   ], f(w) = 0.000025
```

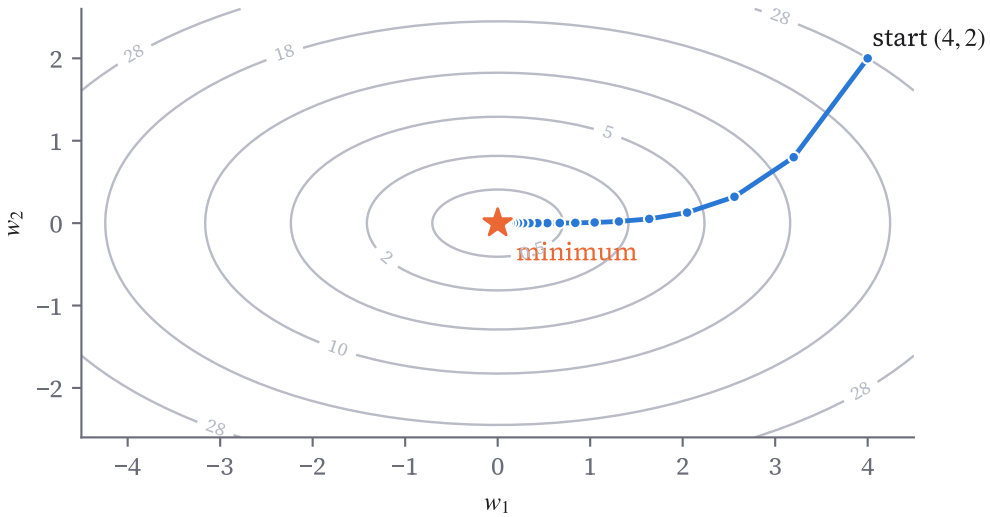



Figure 3.2 — Gradient descent on $f(w_1, w_2) = w_1^2 + 3w_2^2$, starting at (4, 2) with $\eta = 0.1$. Contour lines join points with the same value of f.
រូបទី ៣.២ — ការចុះតាមក្រាដ្យង់ ចាប់ផ្តើមពី (4, 2) ជាមួយ $\eta = 0.1$។ ខ្សែកម្ពស់ភ្ជាប់ចំណុចដែលមានតម្លៃ f ដូចគ្នា។

Notice in Figure 3.2 that $w_2$ shrinks much faster than $w_1$. The surface is steeper in the $w_2$ direction (the factor 3), so the gradient there is larger. After 30 steps the point is very

close to the true minimum at $(0, 0)$.

> សូមកត់សម្គាល់ក្នុងរូបទី ៣.២ ថា $w_2$ ថយចុះលឿនជាង $w_1$ ច្រើន។ ផ្ទៃនោះចោតជាងក្នុងទិស $w_2$ (មេគុណ 3) ដូច្នេះក្រាដ្យង់នៅទីនោះធំជាង។ ក្រោយ ៣០ ជំហាន ចំណុចនោះខិតជិតអប្បបរមាពិតត្រង់ $(0, 0)$ ណាស់។

---

## Exercises 3

លំហាត់ ៣

1. Differentiate $f(x) = 5x^3 - 4x^2 + 7$.
   គណនាដេរីវេនៃ $f(x)$។
2. Use the chain rule to differentiate $g(x) = e^{3x^2}$.
   ប្រើវិធានខ្សែសង្វាក់ដើម្បីគណនាដេរីវេ។
3. Find all partial derivatives of $f(x, y) = x^2 y + 3y^2$ and evaluate $\nabla f(1, 2)$.
   រកដេរីវេដោយផ្នែក ហើយគណនាក្រាដ្យង់ត្រង់ $(1, 2)$។
4. Run the gradient descent listing with $\eta = 0.4$. What happens to $w_2$, and why?
   ដំណើរការកូដជាមួយ $\eta = 0.4$។ តើមានអ្វីកើតឡើងចំពោះ $w_2$ ហើយហេតុអ្វី?
5. Where is the minimum of $f(x) = x^2 - 6x + 10$? Solve $f'(x) = 0$ by hand.
   រកអប្បបរមាដោយដោះស្រាយ $f'(x) = 0$។

CHAPTER 4

# PROBABILITY

## ប្រូបាប

IN THIS CHAPTER ក្នុងជំពូកនេះ

- Use the basic rules of probability and conditional probability
- Apply Bayes' theorem to a real decision
- Work with random variables, expectation, variance, and the binomial and normal distributions
- ប្រើច្បាប់មូលដ្ឋាននៃប្រូបាប និងប្រូបាបមានលក្ខខណ្ឌ
- អនុវត្តទ្រឹស្តីបទបាយេស ក្នុងការសម្រេចចិត្តពិត
- ធ្វើការជាមួយអថេរចៃដន្យ សង្ឃឹមគណិត វ៉ារ្យង់ និងច្បាប់ទ្វេធា និងនរម៉ាល់

### 4.1 Events and the rules of probability

ព្រឹត្តិការណ៍ និងច្បាប់ប្រូបាប

An **experiment** is any process with an uncertain result, such as rolling a die or a customer visiting a shop. The set of all possible results is the **sample space** $\Omega$, and an **event** $A$ is a subset of it. The probability $P(A)$ is a number between 0 (impossible) and 1 (certain). When all outcomes are equally likely, $P(A) = \dfrac{\text{number of outcomes in } A}{\text{number of outcomes in } \Omega}$.

**ពិសោធន៍ (experiment)** គឺជាដំណើរការណាមួយដែលលទ្ធផលមិនប្រាកដ ដូចជាការបោះគ្រាប់ឡុកឡាក់ ឬអតិថិជនមកហាង។ សំណុំលទ្ធផលដែលអាចកើតមានទាំងអស់ហៅថា **លំហសំណាក (sample space)** $\Omega$ ហើយ **ព្រឹត្តិការណ៍ (event)** $A$ គឺជាសំណុំរងរបស់វា។ ប្រូបាប $P(A)$ ជាចំនួនចន្លោះ 0 (មិនអាចកើតមាន) និង 1 (ប្រាកដ)។

KEY RULES ច្បាប់សំខាន់

$$P(\text{not } A) = 1 - P(A) \qquad P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

$$P(A \cap B) = P(A)\,P(B) \quad \text{only if } A \text{ and } B \text{ are independent}$$

*Worked example.* Roll two fair dice. There are $6 \times 6 = 36$ equally likely outcomes, and six of them sum to 7: (1,6), (2,5), (3,4), (4,3), (5,2), (6,1). So $P(\text{sum} = 7) = 6/36 \approx 0.167$.

ឧទាហរណ៍៖ បោះគ្រាប់ឡុកឡាក់ពីរ។ មានលទ្ធផល 36 ដែលអាចកើតមានស្មើគ្នា ហើយប្រាំមួយក្នុងចំណោមនោះមានផលបូក 7។ ដូច្នេះ $P(S = 7) = 6/36 \approx 0.167$ ដែល $S$ ជាផលបូក។ ព្រឹត្តិការណ៍ពីរ **ឯករាជ្យ (independent)** បើការដឹងមួយមិនផ្លាស់ប្តូរប្រូបាប៊ីនៃមួយទៀត។

## 4.2 Conditional probability and Bayes' theorem

ប្រូបាប៊ីមានលក្ខខណ្ឌ និងទ្រឹស្តីបទបាយេស

The **conditional probability** $P(A \mid B)$ is the probability of $A$ given that $B$ has happened: $P(A \mid B) = P(A \cap B)/P(B)$. Turning this around gives **Bayes' theorem**, which updates a belief when new evidence arrives [7]:

KEY FORMULA រូបមន្តសំខាន់

$$P(A \mid B) = \frac{P(B \mid A)\,P(A)}{P(B)}, \qquad P(B) = P(B \mid A)P(A) + P(B \mid \text{not } A)P(\text{not } A)$$

**ប្រូបាប៊ីមានលក្ខខណ្ឌ (conditional probability)** $P(A \mid B)$ គឺប្រូបាប៊ីនៃ $A$ ដោយដឹងថា $B$ បានកើតឡើងរួចហើយ។ ការបង្វិលរូបមន្តនេះ ផ្តល់ **ទ្រឹស្តីបទបាយេស (Bayes' theorem)** ដែលធ្វើបច្ចុប្បន្នភាពជំនឿរបស់យើង នៅពេលភស្តុតាងថ្មីមកដល់។

*Worked example: a medical test.* A disease affects 1% of people. A test detects 95% of sick people, but also gives a positive result for 5% of healthy people. If your test is positive, how likely is it that you are sick? Many people guess 95%. Bayes' theorem gives a very different answer:

$$P(D \mid +) = \frac{0.95 \times 0.01}{0.95 \times 0.01 + 0.05 \times 0.99} = \frac{0.0095}{0.059} \approx 0.161.$$

Only about 16%! Because the disease is rare, most positive results come from the large healthy group. The same reasoning explains why fraud alerts and spam filters produce many false alarms.

**ឧទាហរណ៍៖ តេស្តវេជ្ជសាស្ត្រ។** ជំងឺមួយកើតលើមនុស្ស 1%។ តេស្តរកឃើញ 95% នៃអ្នកជំងឺ ប៉ុន្តែក៏ផ្តល់លទ្ធផលវិជ្ជមានសម្រាប់ 5% នៃអ្នកមានសុខភាពល្អដែរ។ បើតេស្តរបស់អ្នកវិជ្ជមាន តើប្រូបាប៊ីដែលអ្នកមានជំងឺប៉ុន្មាន? មនុស្សជាច្រើនទាយថា 95% ប៉ុន្តែទ្រឹស្តីបទបាយេសផ្តល់ចម្លើយត្រឹមតែប្រហែល 16% ប៉ុណ្ណោះ! ដោយសារជំងឺនេះកម្រ លទ្ធផលវិជ្ជមានភាគច្រើនមកពីក្រុមមនុស្សមានសុខភាពល្អដែលមានចំនួនច្រើន។ ហេតុផលដូចគ្នានេះពន្យល់ថាហេតុអ្វីការជូនដំណឹងពីការក្លែងបន្លំ និងតម្រងសារឥតបានការ (spam) មានការជូនដំណឹងខុសច្រើន។

PYTHON LISTING 4.1

```python
# A disease affects 1% of people.
# The test catches 95% of sick people (sensitivity)
# and wrongly flags 5% of healthy people (false positive rate).
p_d = 0.01
p_pos_given_d = 0.95
p_pos_given_not_d = 0.05

p_pos = p_pos_given_d * p_d + p_pos_given_not_d * (1 - p_d)
p_d_given_pos = p_pos_given_d * p_d / p_pos

print(f"P(positive)          = {p_pos:.4f}")
print(f"P(disease | positive) = {p_d_given_pos:.4f}")
```

OUTPUT · លទ្ធផល

```
P(positive)          = 0.0590
P(disease | positive) = 0.1610
```

## 4.3 Random variables, expectation and variance

### អថេរចៃដន្យ សង្ឃឹមគណិត និងវ៉ារ្យង់

A **random variable** $X$ assigns a number to each outcome, for example the sum of two dice. Its **expected value** (expectation) is the long-run average, and its **variance** measures how far values typically spread from that average:

KEY FORMULAS រូបមន្តសំខាន់

$$E[X] = \sum_{x} x\,P(X = x), \qquad \operatorname{Var}(X) = E\big[(X - E[X])^2\big], \qquad \sigma = \sqrt{\operatorname{Var}(X)}$$

For one fair die, $E[X] = (1 + 2 + \cdots + 6)/6 = 3.5$ and $\operatorname{Var}(X) = 35/12$. For the sum of two independent dice, expectations add ($3.5 + 3.5 = 7$) and so do variances ($35/12 + 35/12 = 35/6 \approx 5.83$). We can check these results by **simulation**: let the computer roll the dice many times and average.

**អថេរចៃដន្យ (random variable)** $X$ ផ្តល់លេខមួយទៅលទ្ធផលនីមួយៗ ឧទាហរណ៍ផលបូកនៃគ្រាប់ឡុកឡាក់ពីរ។ **សង្ឃឹមគណិត (expected value)** របស់វាជាមធ្យមភាគរយៈពេលវែង ហើយ **វ៉ារ្យង់ (variance)** វាស់ថាតម្លៃទាំងនោះខ្ចាត់ខ្ចាយឆ្ងាយពីមធ្យមភាគប៉ុណ្ណា។ $\sigma$ ហៅថា **គម្លាតស្តង់ដារ (standard deviation)**។ យើងអាចផ្ទៀងផ្ទាត់លទ្ធផលទាំងនេះដោយ **ការក្លែងធ្វើ (simulation)**៖ ឱ្យកុំព្យូទ័របោះគ្រាប់ឡុកឡាក់ច្រើនដង ហើយយកមធ្យមភាគ។

PYTHON LISTING 4.2

```python
import numpy as np

rng = np.random.default_rng(seed=42)

# Roll two dice 100,000 times
rolls = rng.integers(1, 7, size=(100_000, 2))
total = rolls.sum(axis=1)

print("P(sum = 7) ≈", round(np.mean(total == 7), 4), " exact:", round(6/36, 4))
print("E[sum]     ≈", round(total.mean(), 3), "  exact: 7")
print("Var[sum]   ≈", round(total.var(), 3), " exact:", round(35/6, 3))
```

OUTPUT · លទ្ធផល

```
P(sum = 7) ≈ 0.1683  exact: 0.1667
E[sum]     ≈ 7.005   exact: 7
Var[sum]   ≈ 5.817  exact: 5.833
```

## 4.4 Two important distributions

ច្បាប់ប្រូបាបសំខាន់ពីរ

### Binomial distribution ច្បាប់ទ្វេធា

Repeat a yes/no trial $n$ times, each with success probability $p$, and count the successes $X$. Then $X$ follows a **binomial distribution**, with

$$P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}, \qquad E[X] = np, \qquad \mathrm{Var}(X) = np(1-p).$$

If 10 customers each buy with probability 0.3, we expect $10 \times 0.3 = 3$ buyers (Figure 4.1).

ធ្វើការសាកល្បង បាទ/ទេ ចំនួន $n$ ដង ដោយប្រូបាបជោគជ័យ $p$ ក្នុងមួយដង ហើយរាប់ចំនួនជោគជ័យ $X$។ នោះ $X$ គោរព **ច្បាប់ទ្វេធា (binomial distribution)**។ បើអតិថិជន ១០ នាក់ម្នាក់ៗទិញដោយប្រូបាប 0.3 យើងរំពឹងថាមានអ្នកទិញ ៣ នាក់។

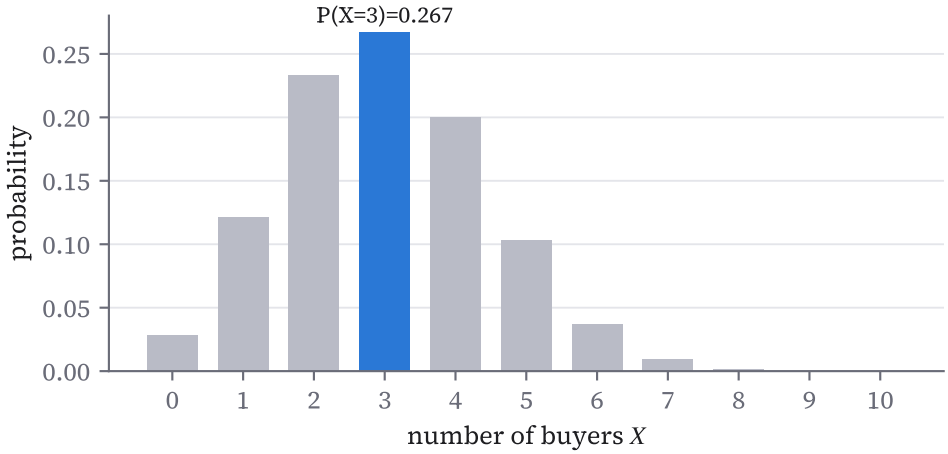



Figure 4.1 — Binomial distribution with n = 10 and p = 0.3. Three buyers is the most likely result.
រូបទី ៤.១ — ចែកចាយទ្វេធា n = 10, p = 0.3។ អ្នកទិញ ៣ នាក់ជាលទ្ធផលដែលទំនងបំផុត។

## Normal distribution ចែកចាយនរម៉ាល់

The **normal distribution** $\mathcal{N}(\mu, \sigma^2)$ is the famous bell curve, described by its mean $\mu$ and standard deviation $\sigma$. Heights, measurement errors and exam scores are often close to normal. A useful rule of thumb is the **68–95–99.7 rule**: about 68% of values lie within $\mu \pm \sigma$, 95% within $\mu \pm 2\sigma$ and 99.7% within $\mu \pm 3\sigma$ [8].

> **ចែកចាយនរម៉ាល់ (normal distribution)** $\mathcal{N}(\mu, \sigma^2)$ គឺជាខ្សែកោងរាងកណ្តឹងដ៏ល្បី ដែលកំណត់ដោយមធ្យមភាគ $\mu$ និងគម្លាតស្តង់ដារ $\sigma$។ កម្ពស់ កំហុសរង្វាស់ និងពិន្ទុប្រឡង ច្រើនតែជិតនឹងនរម៉ាល់។ ច្បាប់ងាយចាំ **68–95–99.7**៖ ប្រហែល 68% នៃតម្លៃស្ថិតក្នុង $\mu \pm \sigma$ 95% ក្នុង $\mu \pm 2\sigma$ និង 99.7% ក្នុង $\mu \pm 3\sigma$។

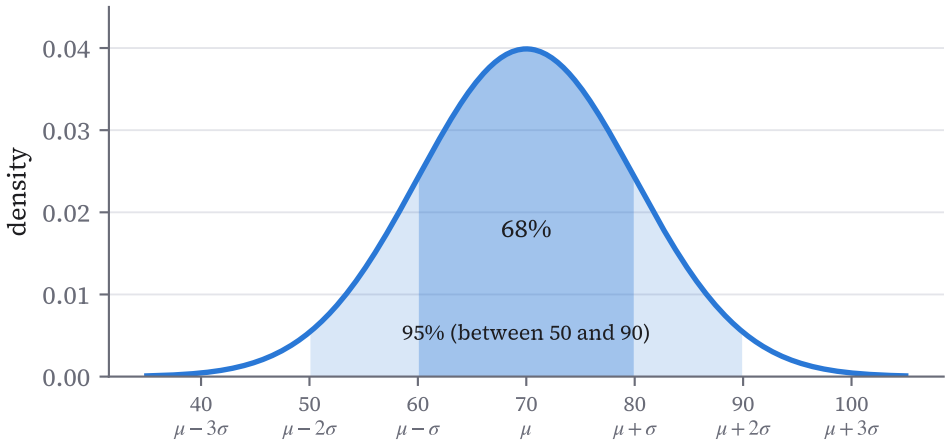



Figure 4.2 — Exam scores following N(70, $10^2$). The dark band holds 68% of students, the light band 95%.
រូបទី ៤.២ — ពិន្ទុប្រឡងតាមច្បាប់ N(70, $10^2$)។ តំបន់ងងឹតមាននិស្សិត 68% តំបន់ភ្លឺ 95%។

SciPy's `stats` module gives exact probabilities for both distributions [9]. Note how the last line of the output reproduces the 68% rule.

ម៉ូឌុល `stats` របស់ SciPy ផ្តល់ប្រូបាបពិតប្រាកដសម្រាប់ច្បាប់ទាំងពីរ។ សូមមើលបន្ទាត់ចុងក្រោយនៃលទ្ធផលដែលបញ្ជាក់ច្បាប់ 68% ម្តងទៀត។

PYTHON LISTING 4.3

```python
from scipy import stats

# Binomial: 10 customers, each buys with p = 0.3
X = stats.binom(n=10, p=0.3)
print("P(X = 3)  =", round(X.pmf(3), 4))
print("P(X <= 2) =", round(X.cdf(2), 4))
print("E[X] =", X.mean(), " Var[X] =", round(X.var(), 2))

# Normal: exam scores with mean 70, std 10
Z = stats.norm(loc=70, scale=10)
print("P(score > 85)      =", round(1 - Z.cdf(85), 4))
print("P(60 < score < 80) =", round(Z.cdf(80) - Z.cdf(60), 4))
```

OUTPUT · លទ្ធផល

```
P(X = 3)  = 0.2668
P(X <= 2) = 0.3828
E[X] = 3.0  Var[X] = 2.1
P(score > 85)      = 0.0668
P(60 < score < 80) = 0.6827
```

## Exercises 4

លំហាត់ ៤

1. A card is drawn from a standard 52-card deck. Find $P(\text{heart or king})$.
   ទាញសន្លឹកបៀមួយ។ រកប្រូបាបដែលបានបេះដូង ឬស្តេច។

2. Redo the medical test example with a disease rate of 10% instead of 1%. How does $P(D \mid +)$ change?
   គណនាឡើងវិញជាមួយអត្រាជំងឺ 10%។ តើលទ្ធផលប្រែប្រួលយ៉ាងដូចម្តេច?

3. A quiz has 8 multiple-choice questions with 4 options each. A student guesses every answer. What is the expected number of correct answers, and $P(X \geq 6)$?
   សិស្សទាយចម្លើយទាំងអស់។ រកចំនួនចម្លើយត្រូវដែលរំពឹងទុក និង $P(X \geq 6)$។

4. Delivery times are $\mathcal{N}(30, 5^2)$ minutes. What fraction of deliveries take more than 40 minutes?
   តើការដឹកជញ្ជូនប៉ុន្មានភាគរយ ចំណាយពេលលើស ៤០ នាទី?

5. Simulate 10,000 coin flips with NumPy and check that the proportion of heads is close to 0.5.
   ក្លែងធ្វើការបោះកាក់ ១០,០០០ ដងជាមួយ NumPy។

CHAPTER 5

# DESCRIPTIVE STATISTICS

## ស្ថិតិពិពណ៌នា

IN THIS CHAPTER ក្នុងជំពូកនេះ

- Summarise the centre of data with the mean, median and mode
- Measure spread with the variance, standard deviation and IQR
- Measure how two variables move together with covariance and correlation
- សង្ខេបចំណុចកណ្តាលនៃទិន្នន័យ ដោយមធ្យមភាគ មេដ្យាន និងម៉ូត
- វាស់ការខ្ចាត់ខ្ចាយ ដោយវ៉ារ្យង់ គម្លាតស្តង់ដារ និង IQR
- វាស់របៀបដែលអថេរពីរប្រែប្រួលជាមួយគ្នា ដោយកូវ៉ារ្យង់ និងសហសម្ព័ន្ធ

Probability starts from a model and predicts data. Statistics works in the other direction: it starts from data and tries to learn about the world. The first step is always to **describe** the data you have [10]. In this chapter we use a small synthetic dataset of 40 students: weekly study hours and final exam score.

> ប្រូបាបចាប់ផ្តើមពីម៉ូដែល ហើយព្យាករណ៍ទិន្នន័យ។ ស្ថិតិធ្វើការក្នុងទិសផ្ទុយ៖ វាចាប់ផ្តើមពីទិន្នន័យ ហើយព្យាយាមរៀនអំពីពិភពលោក។ ជំហានដំបូងជានិច្ចគឺ **ពិពណ៌នា** ទិន្នន័យដែលអ្នកមាន។ ក្នុងជំពូកនេះ យើងប្រើសំណុំទិន្នន័យសិប្បនិម្មិតតូចមួយរបស់និស្សិត ៤០ នាក់៖ ម៉ោងសិក្សាប្រចាំសប្តាហ៍ និងពិន្ទុប្រឡងចុងក្រោយ។

### 5.1 Measures of centre

រង្វាស់ចំណុចកណ្តាល

The **mean** $\bar{x} = \frac{1}{n}\sum x_i$ is the balance point of the data. The **median** is the middle value after sorting (the average of the two middle values when $n$ is even). The **mode** is the most frequent value. The mean uses every value, so a single extreme value can pull it far away; the median is **robust** to outliers.

*Worked example.* Monthly salaries of five staff (million riel): 1.2, 1.4, 1.5, 1.6, 12.0. The mean is $17.7/5 = 3.54$, but the median is 1.5. The median describes a typical staff member much better here; this is why reports on income usually quote the median.

**មធ្យមភាគ (mean)** ជាចំណុចលំនឹងនៃទិន្នន័យ។ **មេដ្យាន (median)** ជាតម្លៃកណ្តាលក្រោយពេលតម្រៀប។ **ម៉ូត (mode)** ជាតម្លៃដែលលេចឡើងញឹកញាប់បំផុត។ មធ្យមភាគប្រើតម្លៃទាំងអស់ ដូច្នេះតម្លៃជ្រុលតែមួយអាចទាញវាឱ្យឆ្ងាយ ចំណែកមេដ្យានវិញ **រឹងមាំ (robust)** ចំពោះតម្លៃជ្រុល (outlier)។

ឧទាហរណ៍៖ ប្រាក់ខែបុគ្គលិក ៥ នាក់ (លានរៀល)៖ 1.2, 1.4, 1.5, 1.6, 12.0។ មធ្យមភាគគឺ 3.54 ប៉ុន្តែមេដ្យានគឺ 1.5។ មេដ្យានពិពណ៌នាបុគ្គលិកធម្មតាបានល្អជាង ដែលហេតុនេះរបាយការណ៍ប្រាក់ចំណូលតែងប្រើមេដ្យាន។

## 5.2 Measures of spread

រង្វាស់ការខ្ចាត់ខ្ចាយ

Two classes can have the same average score but very different spreads. The **sample variance** averages the squared distances from the mean, and the **standard deviation** is its square root, in the same units as the data:

KEY FORMULAS រូបមន្តសំខាន់

$$s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2, \qquad s = \sqrt{s^2}, \qquad \text{IQR} = Q_3 - Q_1$$

We divide by $n-1$ rather than $n$ for a sample; this **Bessel's correction** makes $s^2$ an unbiased estimate of the population variance. pandas uses $n-1$ by default, while NumPy's `np.var` uses $n$ unless you pass `ddof=1`. The **interquartile range** (IQR) is the width of the middle 50% of the data, between the 25th percentile $Q_1$ and the 75th percentile $Q_3$. Like the median, it ignores outliers.

ថ្នាក់ពីរអាចមានពិន្ទុមធ្យមដូចគ្នា ប៉ុន្តែការខ្ចាត់ខ្ចាយខុសគ្នាខ្លាំង។ **វ៉ារ្យង់សំណាក (sample variance)** យកមធ្យមភាគនៃចម្ងាយការ៉េពីមធ្យមភាគ ហើយ **គម្លាតស្តង់ដារ** ជាឫសការ៉េរបស់វា ដែលមានឯកតាដូចទិន្នន័យ។ យើងចែកនឹង $n-1$ សម្រាប់សំណាក (ហៅថា Bessel's correction)។ pandas ប្រើ $n-1$ តាមលំនាំដើម ចំណែក `np.var` ប្រើ $n$ លុះត្រាតែអ្នកដាក់ `ddof=1` ។ **គម្លាតអន្តរកាទីល (IQR)** ជាទទឹងនៃ 50% កណ្តាលនៃទិន្នន័យ។

PYTHON LISTING 5.1

```python
import numpy as np
import pandas as pd

rng = np.random.default_rng(7)
n = 40
hours = rng.uniform(1, 10, n).round(1)              # study hours / week
score = (45 + 4.5 * hours + rng.normal(0, 6, n)).clip(0, 100).round(0)
df = pd.DataFrame({"hours": hours, "score": score})

print(df.head(4))
print()
print(df["score"].describe().round(2))
print("\nmedian:", df["score"].median())
print("IQR   :", df["score"].quantile(0.75) - df["score"].quantile(0.25))
```

OUTPUT · លទ្ធផល

```
   hours  score
0    6.6   74.0
1    9.1   87.0
2    8.0   81.0
3    3.0   51.0

count    40.00
mean     68.53
std      15.23
min      38.00
25%      56.25
50%      67.50
75%      81.00
max      98.00
Name: score, dtype: float64

median: 67.5
IQR   : 24.75
```

The `describe()` method gives the count, mean, standard deviation, minimum, quartiles and maximum in one call [11]. The mean score is 68.53 and the median 67.5, which are close, so the scores are roughly symmetric. Figure 5.1 (left) confirms this with a histogram.

មេតូដ `describe()` ផ្តល់ចំនួន មធ្យមភាគ គម្លាតស្តង់ដារ អប្បបរមា កាទីល និងអតិបរមា ក្នុងការហៅតែមួយដង។ ពិន្ទុមធ្យមគឺ 68.53 និងមេដ្យាន 67.5 ដែលជិតគ្នា ដូច្នេះពិន្ទុប្រហាក់ប្រហែលស៊ីមេទ្រី។ រូបទី ៥.១ (ខាងឆ្វេង) បញ្ជាក់ចំណុចនេះតាមអ៊ីស្តូក្រាម (histogram)។

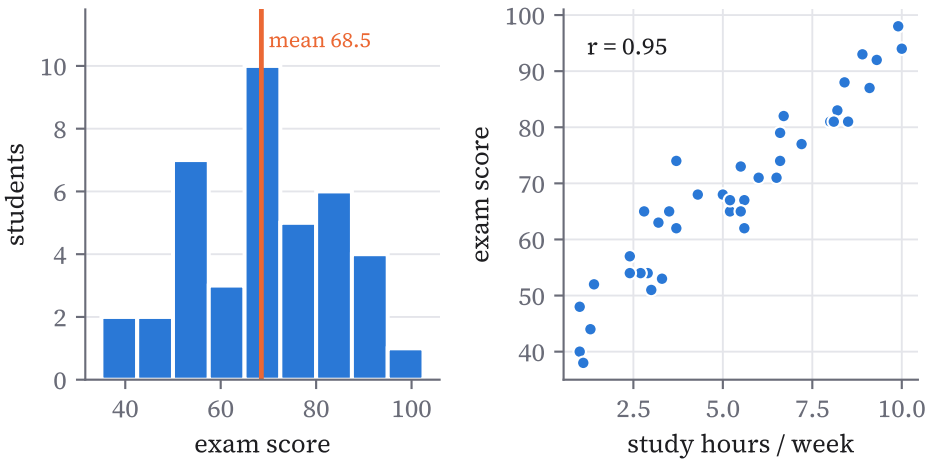



Figure 5.1 — Left: histogram of exam scores with the mean marked. Right: scatter plot of study hours against score.
រូបទី ៥.១ — ឆ្វេង៖ អ៊ីស្តូក្រាមពិន្ទុប្រឡង។ ស្តាំ៖ ក្រាហ្វិកចំណុចនៃម៉ោងសិក្សា និងពិន្ទុ។

## 5.3 Covariance and correlation

### កូវ៉ារ្យង់ និងសហសម្ព័ន្ធ

Do students who study more score higher? The **covariance** is positive when two variables tend to be above their means together, and negative when one tends to be high while the other is low. Its size depends on the units, so we usually standardise it to the **Pearson correlation coefficient** $r$, which always lies between $-1$ and $+1$:

KEY FORMULAS  រូបមន្តសំខាន់

$$\operatorname{cov}(x,y) = \frac{1}{n-1}\sum_{i=1}^{n}(x_i-\bar{x})(y_i-\bar{y}), \qquad r = \frac{\operatorname{cov}(x,y)}{s_x\, s_y}$$

| Value of $r$ | Meaning | អត្ថន័យ |
|---|---|---|
| close to $+1$ | strong positive linear relationship | ទំនាក់ទំនងលីនេអ៊ែរវិជ្ជមានខ្លាំង |
| close to $0$ | no linear relationship | គ្មានទំនាក់ទំនងលីនេអ៊ែរ |
| close to $-1$ | strong negative linear relationship | ទំនាក់ទំនងលីនេអ៊ែរអវិជ្ជមានខ្លាំង |

តើនិស្សិតដែលរៀនច្រើន ទទួលបានពិន្ទុខ្ពស់ជាងឬទេ? **កូវ៉ារ្យង់ (covariance)** វិជ្ជមាន នៅពេលអថេរពីរមាននិន្នាការខ្ពស់ជាងមធ្យមភាគជាមួយគ្នា ហើយអវិជ្ជមាន នៅពេលមួយខ្ពស់ ខណៈមួយទៀតទាប។ ទំហំរបស់វា

អាស្រ័យលើឯកតា ដូច្នេះយើងជាធម្មតាប្តូរវាទៅជា **មេគុណសហសម្ពន្ធ Pearson (correlation)** $r$ ដែលស្ថិតនៅចន្លោះ $-1$ និង $+1$ ជានិច្ច។

PYTHON LISTING 5.2

```python
cov = df["hours"].cov(df["score"])
r = df["hours"].corr(df["score"])

print("covariance  =", round(cov, 2))
print("correlation =", round(r, 3))
print()
print(df.corr().round(3))
```

OUTPUT · លទ្ធផល

```
covariance  = 39.16
correlation = 0.95

       hours  score
hours   1.00   0.95
score   0.95   1.00
```

Here $r = 0.95$, a very strong positive relationship, which matches the upward cloud of points in Figure 5.1 (right).

IN DATA SCIENCE ក្នុងវិទ្យាសាស្ត្រទិន្នន័យ

**Correlation is not causation.** Ice-cream sales and drowning accidents are correlated because both rise in hot weather, not because one causes the other. Also, $r$ only measures *linear* relationships: a perfect U-shaped pattern can have $r \approx 0$. Always plot your data before trusting a single number.

**សហសម្ពន្ធមិនមែនជាមូលហេតុទេ។** ការលក់ការ៉េម និងគ្រោះថ្នាក់លង់ទឹក មានសហសម្ពន្ធគ្នា ព្រោះទាំងពីរកើនឡើងពេលអាកាសធាតុក្តៅ មិនមែនព្រោះមួយបង្កឱ្យមួយទៀតនោះទេ។ ម្យ៉ាងទៀត $r$ វាស់តែទំនាក់ទំនង *លីនេអ៊ែរ* ប៉ុណ្ណោះ។ ត្រូវគូសក្រាហ្វិកទិន្នន័យជានិច្ច មុនពេលជឿលើលេខតែមួយ។

---

## Exercises 5

លំហាត់ ៥

1. Find the mean, median and mode of 3, 7, 7, 2, 9, 7, 5.
   រកមធ្យមភាគ មេដ្យាន និងម៉ូត។
2. Compute the sample variance and standard deviation of 2, 4, 4, 4, 5, 5, 7, 9 by hand.
   គណនាវ៉ារ្យង់សំណាក និងគម្លាតស្តង់ដារដោយដៃ។

3. Add an outlier of 0 hours and 100 points to the student data. Which changes more: the mean score or the median score?
   បន្ថែមតម្លៃជ្រុលមួយ។ តើមធ្យមភាគ ឬមេដ្យានប្រែប្រួលច្រើនជាង?
4. Give a real example from Cambodia of two variables that are correlated but where one does not cause the other.
   ផ្តល់ឧទាហរណ៍ពិតពីប្រទេសកម្ពុជា នៃអថេរពីរដែលមានសហសម្ព័ន្ធ ប៉ុន្តែមួយមិនបង្កឱ្យមួយទៀត។
5. Use `np.corrcoef` to find $r$ for $x = (1, 2, 3, 4, 5)$ and $y = (2, 4, 5, 4, 5)$.
   ប្រើ `np.corrcoef` ដើម្បីរក $r$។

CHAPTER 6

# INFERENTIAL STATISTICS

## ស្ថិតិសន្និដ្ឋាន

IN THIS CHAPTER ក្នុងជំពូកនេះ

- Explain the difference between a population and a sample
- See the Central Limit Theorem at work with a simulation
- Build a confidence interval and run a hypothesis test (A/B test) with SciPy
- ពន្យល់ភាពខុសគ្នារវាងសកលស្ថិតិ និងសំណាក
- មើលទ្រឹស្តីបទលីមីតកណ្តាល តាមរយៈការក្លែងធ្វើ
- បង្កើតចន្លោះទំនុកចិត្ត និងធ្វើតេស្តសម្មតិកម្ម (A/B test) ជាមួយ SciPy

### 6.1 Populations and samples

សកលស្ថិតិ និងសំណាក

We usually want to know something about a whole **population**, such as the average monthly spending of every mobile-banking user in Cambodia. Measuring everyone is too expensive, so we measure a random **sample** and use it to estimate the population value. Numbers that describe the population are **parameters** (written with Greek letters, $\mu$, $\sigma$); numbers computed from a sample are **statistics** ($\bar{x}$, $s$). Inferential statistics asks: how close is $\bar{x}$ likely to be to $\mu$? [8]

> ជាធម្មតា យើងចង់ដឹងអំពី **សកលស្ថិតិ (population)** ទាំងមូល ដូចជាការចំណាយប្រចាំខែជាមធ្យមរបស់អ្នកប្រើប្រាស់ធនាគារចល័តទាំងអស់នៅកម្ពុជា។ ការវាស់មនុស្សទាំងអស់ថ្លៃពេក ដូច្នេះយើងវាស់ **សំណាក (sample)** ចៃដន្យមួយ ហើយប្រើវាដើម្បីប៉ាន់ស្មានតម្លៃនៃសកលស្ថិតិ។ លេខដែលពិពណ៌នាសកលស្ថិតិហៅថា **ប៉ារ៉ាម៉ែត្រ** ($\mu$, $\sigma$) ហើយលេខដែលគណនាពីសំណាកហៅថា **ស្ថិតិ** ($\bar{x}$, $s$)។ ស្ថិតិសន្និដ្ឋានសួរថា៖ តើ $\bar{x}$ ទំនងជានៅជិត $\mu$ ប៉ុណ្ណា?

## 6.2 The Central Limit Theorem

### ទ្រឹស្តីបទលីមីតកណ្តាល

THEOREM ទ្រឹស្តីបទ

Take many random samples of size $n$ from a population with mean $\mu$ and standard deviation $\sigma$. When $n$ is large enough (often $n \geq 30$), the distribution of the sample means is approximately normal with mean $\mu$ and standard deviation $\sigma/\sqrt{n}$, *whatever the shape of the population*.

យកសំណាកចៃដន្យជាច្រើនដែលមានទំហំ $n$ ពីសកលស្ថិតិដែលមានមធ្យមភាគ $\mu$ និងគម្លាតស្តង់ដារ $\sigma$។ នៅពេល $n$ ធំគ្រប់គ្រាន់ (ជាញឹកញាប់ $n \geq 30$) ការបែងចែកនៃមធ្យមភាគសំណាកប្រហាក់ប្រហែលនរម៉ាល់ ដែលមានមធ្យមភាគ $\mu$ និងគម្លាតស្តង់ដារ $\sigma/\sqrt{n}$ *មិនថារាងនៃសកលស្ថិតិយ៉ាងណាក៏ដោយ*។

The quantity $\sigma/\sqrt{n}$ is the **standard error** (SE). It shrinks as the sample grows: four times more data halves the error. The simulation below starts from a strongly skewed population of waiting times, yet the 5,000 sample means form a bell curve (Figure 6.1), and their spread matches $\sigma/\sqrt{n}$ closely.

បរិមាណ $\sigma/\sqrt{n}$ ហៅថា **កំហុសស្តង់ដារ (standard error, SE)**។ វាថយចុះនៅពេលសំណាកធំឡើង៖ ទិន្នន័យច្រើនជាង ៤ ដង កាត់បន្ថយកំហុសពាក់កណ្តាល។ ការក្លែងធ្វើខាងក្រោមចាប់ផ្តើមពីសកលស្ថិតិនៃរយៈពេលរង់ចាំដែលលម្អៀងខ្លាំង ប៉ុន្តែមធ្យមភាគសំណាក ៥,000 បង្កើតបានជាខ្សែកោងរាងកណ្តឹង (រូបទី ៦.9)។

PYTHON LISTING 6.1

```python
import numpy as np

rng = np.random.default_rng(1)

# A skewed population: waiting times (minutes), exponential with mean 5
population = rng.exponential(scale=5, size=1_000_000)

sample_means = [rng.choice(population, size=40).mean() for _ in range(5_000)]

print("population mean      :", round(population.mean(), 3))
print("population std       :", round(population.std(), 3))
print("mean of sample means :", round(np.mean(sample_means), 3))
print("std of sample means  :", round(np.std(sample_means), 3))
print("theory σ/√n          :", round(population.std() / np.sqrt(40), 3))
```

OUTPUT · លទ្ធផល

```
population mean      : 4.991
population std       : 4.981
mean of sample means : 4.996
std of sample means  : 0.797
theory σ/√n          : 0.787
```

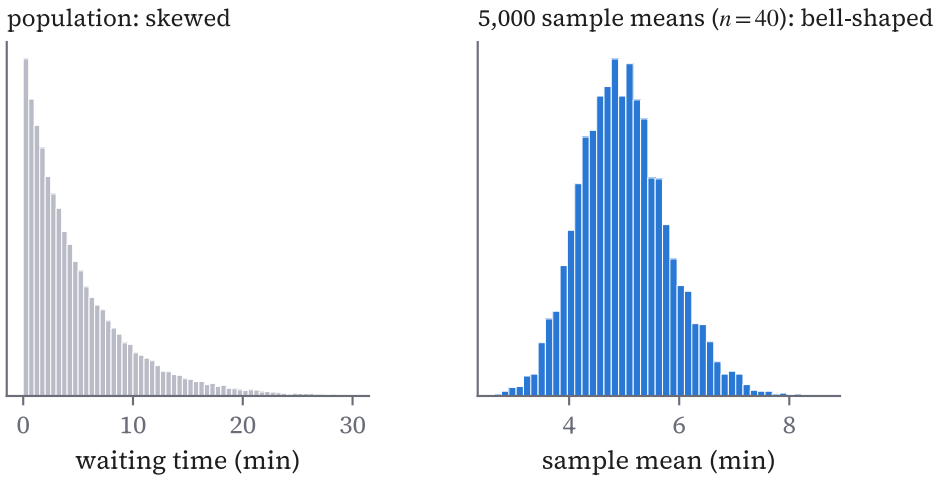



Figure 6.1 — The Central Limit Theorem: a skewed population (left) still gives normally distributed sample means (right).
រូបទី ៦.១ — ទ្រឹស្តីបទលីមីតកណ្តាល៖ សកលស្ថិតិលម្អៀង (ឆ្វេង) នៅតែផ្តល់មធ្យមភាគសំណាកដែលមានរាងនរម៉ាល់ (ស្តាំ)។

## 6.3 Confidence intervals

### ចន្លោះទំនុកចិត្ត

A single estimate such as $\bar{x} = 68.5$ hides its uncertainty. A **95% confidence interval** gives a range of plausible values for $\mu$. When $\sigma$ is unknown and estimated by $s$, we use the $t$-

distribution with $n-1$ degrees of freedom:

KEY FORMULA រូបមន្តសំខាន់

$$\bar{x} \pm t^* \frac{s}{\sqrt{n}}, \qquad t^* = \text{the 97.5th percentile of } t_{n-1}$$

The meaning is subtle: if we repeated the whole study many times, about 95% of the intervals built this way would contain the true $\mu$. It does *not* mean there is a 95% probability that $\mu$ lies in this particular interval.

ការប៉ាន់ស្មានតែមួយ ដូចជា $\bar{x} = 68.5$ លាក់ភាពមិនប្រាកដរបស់វា។ **ចន្លោះទំនុកចិត្ត 95% (confidence interval)** ផ្តល់ចន្លោះតម្លៃដែលអាចទទួលយកបានសម្រាប់ $\mu$។ នៅពេល $\sigma$ មិនស្គាល់ ហើយត្រូវប៉ាន់ស្មានដោយ $s$ យើងប្រើច្បាប់ $t$ ដែលមានដឺក្រេសេរីភាព $n-1$។ អត្ថន័យរបស់វា៖ បើយើងធ្វើការសិក្សាទាំងមូលម្តងហើយម្តងទៀត ប្រហែល 95% នៃចន្លោះដែលបង្កើតតាមវិធីនេះ នឹងមាន $\mu$ ពិតនៅខាងក្នុង។

PYTHON LISTING 6.2

```python
import numpy as np
from scipy import stats

sample = df["score"].to_numpy()        # the 40 scores from Chapter 5
n = len(sample)
mean = sample.mean()
se = sample.std(ddof=1) / np.sqrt(n)  # standard error
t_crit = stats.t.ppf(0.975, df=n - 1)

low, high = mean - t_crit * se, mean + t_crit * se
print(f"mean = {mean:.2f}, SE = {se:.2f}, t* = {t_crit:.3f}")
print(f"95% CI = ({low:.2f}, {high:.2f})")
```

OUTPUT · លទ្ធផល

```
mean = 68.53, SE = 2.41, t* = 2.023
95% CI = (63.65, 73.40)
```

We can say: we are 95% confident that the mean score of all students like these lies between 63.65 and 73.40.

## 6.4 Hypothesis testing and p-values

តេស្តសម្មតិកម្ម និងតម្លៃ p

A company tests two website designs. Design B seems to keep visitors longer, but is the difference real or just luck? A **hypothesis test** answers this in four steps:

1. State the **null hypothesis** $H_0$: there is no difference ($\mu_A = \mu_B$), and the **alternative** $H_1$: there is a difference.

2. Choose a **significance level**, usually $\alpha = 0.05$.
3. Compute a test statistic from the data, here Welch's $t$-statistic, and its **p-value**: the probability of seeing a difference at least this large *if $H_0$ were true*.
4. If $p < \alpha$, reject $H_0$; otherwise we do not have enough evidence to reject it.

ក្រុមហ៊ុនមួយសាកល្បងការរចនាគេហទំព័រពីរ។ ការរចនា B ហាក់ដូចជារក្សាអ្នកទស្សនាបានយូរជាង ប៉ុន្តែតើភាពខុសគ្នានោះពិត ឬគ្រាន់តែជាសំណាងល្អ? **តេស្តសម្មតិកម្ម (hypothesis test)** ឆ្លើយសំណួរនេះតាមបួនជំហាន៖ (១) កំណត់ **សម្មតិកម្មសូន្យ** $H_0$ ថាគ្មានភាពខុសគ្នា និងសម្មតិកម្មជំនួស $H_1$។ (២) ជ្រើសរើស **កម្រិតសារៈសំខាន់** ជាធម្មតា $\alpha = 0.05$។ (៣) គណនាស្ថិតិតេស្ត និង **តម្លៃ p (p-value)**៖ ប្រូបាប៊ីនៃការឃើញភាពខុសគ្នាធំយ៉ាងហោចណាស់ប៉ុណ្ណេះ *បើ $H_0$ ពិត*។ (៤) បើ $p < \alpha$ បដិសេធ $H_0$។

PYTHON LISTING 6.3

```python
import numpy as np
from scipy import stats

rng = np.random.default_rng(3)
# Time on page (seconds) for two website designs
design_a = rng.normal(52, 12, 60)
design_b = rng.normal(58, 12, 60)

t, p = stats.ttest_ind(design_b, design_a, equal_var=False)
print(f"mean A = {design_a.mean():.2f} s, mean B = {design_b.mean():.2f} s")
print(f"t = {t:.3f}, p-value = {p:.4f}")
print("Reject H0 at 5%?", p < 0.05)
```

OUTPUT · លទ្ធផល

```
mean A = 51.84 s, mean B = 57.38 s
t = 2.314, p-value = 0.0224
Reject H0 at 5%? True
```

The p-value is 0.0224, which is below 0.05, so we reject $H_0$: the data give evidence that design B keeps visitors longer, by about 5.5 seconds on average.

IN DATA SCIENCE ក្នុងវិទ្យាសាស្ត្រទិន្នន័យ

A small p-value means the result is unlikely to be pure chance. It does not tell you that the effect is large or important. A 0.1-second improvement can be "significant" with a million users and still be worthless to the business. Report the size of the effect and a confidence interval, not only the p-value [10].

តម្លៃ p តូចមានន័យថាលទ្ធផលមិនទំនងជាចៃដន្យសុទ្ធសាធ។ វាមិនប្រាប់ថាឥទ្ធិពលនោះធំ ឬសំខាន់ទេ។ ការកែលម្អ 0.1 វិនាទីអាច «មានសារៈសំខាន់ស្ថិតិ» ជាមួយអ្នកប្រើប្រាស់មួយលាននាក់ ប៉ុន្តែគ្មានតម្លៃសម្រាប់អាជីវកម្មសោះ។ ត្រូវរាយការណ៍ទំហំនៃឥទ្ធិពល និងចន្លោះទំនុកចិត្ត មិនមែនតែតម្លៃ p ប៉ុណ្ណោះទេ។

## Exercises 6

លំហាត់ ៦

1. A population has $\sigma = 12$. What is the standard error of the mean for $n = 36$? For $n = 144$?
   រកកំហុសស្តង់ដារសម្រាប់ $n = 36$ និង $n = 144$។
2. A sample of 25 phone batteries has mean life 18.2 hours and $s = 2.5$. Build a 95% confidence interval ($t^* = 2.064$).
   បង្កើតចន្លោះទំនុកចិត្ត 95%។
3. Explain in your own words, in Khmer or English, what a p-value of 0.30 means.
   ពន្យល់ដោយពាក្យរបស់អ្នក ពីអត្ថន័យនៃតម្លៃ p = 0.30។
4. Change the CLT listing to use samples of size 5 instead of 40. What happens to the shape and spread of the sample means?
   ប្តូរទំហំសំណាកទៅ 5។ តើរាង និងការខ្ចាត់ខ្ចាយប្រែប្រួលយ៉ាងដូចម្តេច?
5. In the A/B test, why is it important that visitors are assigned to A or B at random?
   ហេតុអ្វីការបែងចែកអ្នកទស្សនាទៅ A ឬ B ដោយចៃដន្យសំខាន់?

CHAPTER 7

# PROJECT: LINEAR REGRESSION FROM SCRATCH

## គម្រោង៖ តំរែតំរង់លីនេអ៊ែរពីដំបូង

IN THIS CHAPTER ក្នុងជំពូកនេះ

- Combine linear algebra, calculus and statistics in one model
- Fit a line with the normal equation and with gradient descent
- Evaluate the model with MSE, RMSE and $R^2$, and compare with scikit-learn
- បញ្ចូលពីជគណិតលីនេអ៊ែរ កាល់គុល និងស្ថិតិ ក្នុងម៉ូដែលតែមួយ
- គូសបន្ទាត់ដោយសមីការនរម៉ាល់ និងដោយការចុះតាមក្រាដ្យង់
- វាយតម្លៃម៉ូដែលដោយ MSE, RMSE និង $R^2$ ហើយប្រៀបធៀបជាមួយ scikit-learn

## 7.1 The model

### ម៉ូដែល

We return to the 40 students from Chapter 5. We want a rule that predicts a student's exam score $y$ from weekly study hours $x$. The simplest rule is a straight line:

$$\hat{y} = b + m\,x$$

Here $b$ (intercept) is the predicted score for zero hours and $m$ (slope) is the extra points per extra hour. "Learning" means choosing the $b$ and $m$ that fit the data best. With many features $x_1, \dots, x_p$ the same idea becomes $\hat{y} = b + w_1 x_1 + \cdots + w_p x_p$, which in matrix form is $\hat{\mathbf{y}} = X\mathbf{w}$ when we add a column of 1s to $X$ for the intercept [12].

> យើងត្រឡប់ទៅនិស្សិត ៤០ នាក់ពីជំពូកទី ៥។ យើងចង់បានច្បាប់មួយដែលព្យាករណ៍ពិន្ទុប្រឡង $y$ ពីម៉ោងសិក្សាប្រចាំសប្តាហ៍ $x$។ ច្បាប់សាមញ្ញបំផុតគឺបន្ទាត់ត្រង់ $\hat{y} = b + m\,x$។ $b$ (ចំណុចប្រសព្វ) ជាពិន្ទុព្យាករណ៍សម្រាប់សូន្យម៉ោង ហើយ $m$ (មេគុណប្រាប់ទិស) ជាពិន្ទុបន្ថែមក្នុងមួយម៉ោងបន្ថែម។ «ការរៀន» មានន័យថាជ្រើសរើស $b$ និង $m$ ដែលសមនឹងទិន្នន័យល្អបំផុត។ ជាមួយលក្ខណៈច្រើន គំនិតដដែលនេះក្លាយជា $\hat{\mathbf{y}} = X\mathbf{w}$ ក្នុងទម្រង់ម៉ាទ្រីស។

## 7.2 Measuring error: the loss function

### ការវាស់កំហុស៖ អនុគមន៍ខាតបង់

For each student the **residual** $y_i - \hat{y}_i$ is the gap between the true and predicted score. We square the residuals (so positive and negative errors do not cancel, and big errors count more) and average them. This is the **mean squared error**, our loss function:

KEY FORMULA រូបមន្តសំខាន់

$$\text{MSE}(\mathbf{w}) = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2 = \frac{1}{n}\|\mathbf{y} - X\mathbf{w}\|^2$$

MSE is a quadratic, bowl-shaped function of the weights, exactly like $w_1^2 + 3w_2^2$ in Chapter 3. So it has a single lowest point, and we can find it in two ways.

សម្រាប់និស្សិតម្នាក់ៗ **សំណល់ (residual)** $y_i - \hat{y}_i$ ជាគម្លាតរវាងពិន្ទុពិត និងពិន្ទុព្យាករណ៍។ យើងលើកសំណល់ជាការ៉េ (ដើម្បីកុំឱ្យកំហុសវិជ្ជមាន និងអវិជ្ជមានលុបគ្នា ហើយកំហុសធំរាប់ច្រើនជាង) ហើយយកមធ្យមភាគ។ នេះគឺ **កំហុសការ៉េមធ្យម (mean squared error, MSE)** ដែលជាអនុគមន៍ខាតបង់ (loss function) របស់យើង។ MSE ជាអនុគមន៍ដឺក្រេទីពីរវាងចាន ដូចក្នុងជំពូកទី ៣ ដូច្នេះវាមានចំណុចទាបបំផុតតែមួយ។

## 7.3 Method 1: the normal equation

### វិធីទី ១៖ សមីការនរម៉ាល់

At the minimum the gradient is zero. Setting $\nabla \text{MSE} = -\frac{2}{n}X^\top(\mathbf{y} - X\mathbf{w}) = \mathbf{0}$ and rearranging gives the **normal equation**, a linear system just like Section 2.5:

KEY FORMULA រូបមន្តសំខាន់

$$X^\top X\,\mathbf{w} = X^\top \mathbf{y} \quad \Rightarrow \quad \mathbf{w} = (X^\top X)^{-1} X^\top \mathbf{y}$$

នៅត្រង់អប្បបរមា ក្រាដ្យង់ស្មើសូន្យ។ ការដាក់ $\nabla \text{MSE} = \mathbf{0}$ ហើយរៀបចំឡើងវិញ ផ្តល់ **សមីការនរម៉ាល់ (normal equation)** ដែលជាប្រព័ន្ធលីនេអ៊ែរដូចផ្នែក ២.៥។ នេះបង្ហាញពីរបៀបដែលពីជគណិតលីនេអ៊ែរ និងកាល់គុលធ្វើការរួមគ្នា។

PYTHON LISTING 7.1

```python
import numpy as np

X = df[["hours"]].to_numpy()
y = df["score"].to_numpy()

# add a column of 1s for the intercept
X_b = np.c_[np.ones(len(X)), X]

# normal equation: w = (XᵀX)⁻¹ Xᵀy
w = np.linalg.solve(X_b.T @ X_b, X_b.T @ y)
print(f"intercept b = {w[0]:.3f}")
print(f"slope     m = {w[1]:.3f}")
```

OUTPUT · លទ្ធផល

```
intercept b = 40.540
slope     m = 5.348
```

So the fitted line is $\hat{y} = 40.54 + 5.348x$: each extra hour of study per week is associated with about 5.3 more points. The data were generated with a true slope of 4.5 plus random noise, so the estimate is close but not exact, as statistics predicts.

ដូច្នេះបន្ទាត់ដែលបានគឺ $\hat{y} = 40.54 + 5.348x$៖ ម៉ោងសិក្សាបន្ថែមនីមួយៗក្នុងមួយសប្តាហ៍ ទាក់ទងនឹងពិន្ទុបន្ថែមប្រហែល 5.3។ ទិន្នន័យនេះត្រូវបានបង្កើតដោយមេគុណប្រាប់ទិសពិត 4.5 បូកនឹងសំឡេងរំខានចៃដន្យ ដូច្នេះការប៉ាន់ស្មានជិត ប៉ុន្តែមិនត្រឹមត្រូវទាំងស្រុងទេ។

## 7.4 Method 2: gradient descent

### វិធីទី ២៖ ការចុះតាមក្រាដ្យង់

The normal equation needs to solve a $p \times p$ system, which becomes slow when there are millions of features. Gradient descent only needs the gradient, so it scales to huge models; it is how neural networks are trained. Start from $\mathbf{w} = \mathbf{0}$ and repeat $\mathbf{w} \leftarrow \mathbf{w} - \eta \frac{2}{n} X^\top (X\mathbf{w} - \mathbf{y})$:

សមីការនរម៉ាល់ត្រូវដោះស្រាយប្រព័ន្ធ $p \times p$ ដែលក្លាយជាយឺតនៅពេលមានលក្ខណៈរាប់លាន។ ការចុះតាមក្រាដ្យង់ត្រូវការតែក្រាដ្យង់ប៉ុណ្ណោះ ដូច្នេះវាអាចប្រើជាមួយម៉ូដែលធំៗបាន ហើយនេះជារបៀបដែលបណ្តាញសរសៃប្រសាទត្រូវបានបង្វឹក។ ចាប់ផ្តើមពី $\mathbf{w} = \mathbf{0}$ ហើយធ្វើបច្ចុប្បន្នភាពម្តងហើយម្តងទៀត។

PYTHON LISTING 7.2

```python
w = np.zeros(2)          # [b, m]
lr = 0.01
n = len(y)
history = []

for epoch in range(5_000):
    y_hat = X_b @ w
    error = y_hat - y
    grad = (2 / n) * X_b.T @ error      # ∇ MSE
    w -= lr * grad
    history.append(np.mean(error ** 2))

print(f"b = {w[0]:.3f}, m = {w[1]:.3f}")
print(f"MSE after   1 epoch : {history[0]:.2f}")
print(f"MSE after 5000 epochs: {history[-1]:.2f}")
```

OUTPUT · លទ្ធផល

```
b = 40.540, m = 5.348
MSE after   1 epoch : 4921.82
MSE after 5000 epochs: 21.92
```

After 5,000 steps (called **epochs**) gradient descent reaches the same $b$ and $m$ as the normal equation. Figure 7.1 shows the fitted line and how the loss fell during training. The flat stretch in the middle of the loss curve is typical: the intercept and slope are on very different scales, so progress slows down. Scaling features to similar ranges (for example, standardising them) usually makes gradient descent much faster.

ក្រោយ ៥,000 ជំហាន (ហៅថា **epoch**) ការចុះតាមក្រាដ្យង់ទទួលបាន $b$ និង $m$ ដូចសមីការនរម៉ាល់។ រូបទី ៧.១ បង្ហាញបន្ទាត់ និងរបៀបដែលកំហុសធ្លាក់ចុះអំឡុងពេលបង្វឹក។ ផ្នែករាបស្មើនៅកណ្តាលខ្សែកោងកំហុស គឺជារឿងធម្មតា ព្រោះចំណុចប្រសព្វ និងមេគុណប្រាប់ទិសមានមាត្រដ្ឋានខុសគ្នាខ្លាំង។ ការធ្វើស្តង់ដារកម្មលក្ខណៈ (feature scaling) ជាធម្មតាធ្វើឱ្យការចុះតាមក្រាដ្យង់លឿនជាងមុនច្រើន។

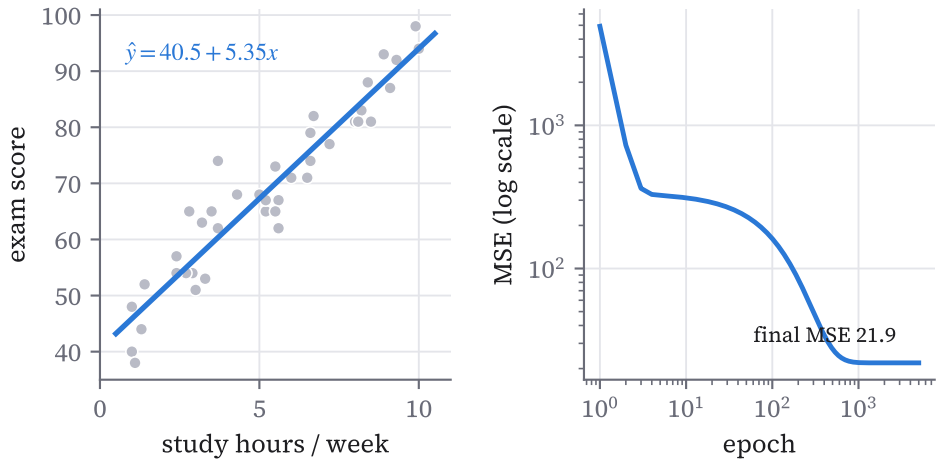



Figure 7.1 — Left: the fitted regression line. Right: MSE during gradient descent (both axes on a log scale).
រូបទី ៧.១ — ឆ្វេង៖ បន្ទាត់តំរែតំរង់។ ស្តាំ៖ MSE អំឡុងពេលចុះតាមក្រាដ្យង់ (អ័ក្សទាំងពីរជាមាត្រដ្ឋានលោការីត)។

## 7.5 Evaluating the model

### ការវាយតម្លៃម៉ូដែល

Three numbers summarise how well a regression fits. **MSE** is the loss itself. **RMSE** $= \sqrt{\text{MSE}}$ is in the original units, so "a typical error of about 4.7 points" is easy to explain. The **coefficient of determination** $R^2$ is the share of the variance in $y$ explained by the model:

KEY FORMULA  រូបមន្តសំខាន់

$$R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}$$

$R^2 = 1$ is a perfect fit and $R^2 = 0$ is no better than always predicting the mean. For simple linear regression, $R^2 = r^2$; here $0.95^2 \approx 0.90$, matching Chapter 5. Finally, we check our work against scikit-learn [13]:

លេខបីសង្ខេបពីភាពសមរបស់តំរែតំរង់។ **MSE** ជាកំហុសខ្លួនឯង។ **RMSE** មានឯកតាដើម ដូច្នេះ «កំហុសធម្មតាប្រហែល 4.7 ពិន្ទុ» ងាយពន្យល់។ **មេគុណកំណត់ (coefficient of determination)** $R^2$ ជាចំណែកនៃវ៉ារ្យង់របស់ $y$ ដែលម៉ូដែលពន្យល់បាន។ $R^2 = 1$ គឺសមឥតខ្ចោះ ហើយ $R^2 = 0$ គឺមិនប្រសើរជាងការព្យាករណ៍មធ្យមភាគជានិច្ចនោះទេ។ សម្រាប់តំរែតំរង់លីនេអ៊ែរសាមញ្ញ $R^2 = r^2$។

PYTHON LISTING 7.3

```python
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error, r2_score

model = LinearRegression().fit(X, y)
pred = model.predict(X)

print(f"sklearn: b = {model.intercept_:.3f}, m = {model.coef_[0]:.3f}")
print(f"MSE  = {mean_squared_error(y, pred):.2f}")
print(f"RMSE = {np.sqrt(mean_squared_error(y, pred)):.2f}")
print(f"R²   = {r2_score(y, pred):.3f}")
print(f"Predicted score for 8 hours: {model.predict([[8]])[0]:.1f}")
```

OUTPUT · លទ្ធផល

```
sklearn: b = 40.540, m = 5.348
MSE  = 21.92
RMSE = 4.68
R²   = 0.903
Predicted score for 8 hours: 83.3
```

scikit-learn gives exactly the same coefficients as our two hand-written methods, an $R^2$ of 0.903 and a predicted score of 83.3 for a student who studies 8 hours a week. In real projects you should also evaluate on a separate **test set** that the model never saw during training; a model that only memorises its training data will look perfect there and fail on new students [12].

scikit-learn ផ្តល់មេគុណដូចគ្នាទាំងស្រុងនឹងវិធីសាស្ត្រទាំងពីរដែលយើងសរសេរដោយដៃ ជាមួយ $R^2$ = 0.903 និងពិន្ទុព្យាករណ៍ 83.3 សម្រាប់និស្សិតដែលរៀន ៨ ម៉ោងក្នុងមួយសប្តាហ៍។ ក្នុងគម្រោងពិត អ្នកក៏ត្រូវវាយតម្លៃលើ **សំណុំតេស្ត (test set)** ដាច់ដោយឡែក ដែលម៉ូដែលមិនធ្លាប់ឃើញអំឡុងពេលបង្វឹក។ ម៉ូដែលដែលគ្រាន់តែទន្ទេញទិន្នន័យបង្វឹក នឹងមើលទៅល្អឥតខ្ចោះ ប៉ុន្តែបរាជ័យលើនិស្សិតថ្មី។

WHAT YOU HAVE LEARNED អ្វីដែលអ្នកបានរៀន

One small model used every chapter: **vectors and matrices** to hold the data (Ch. 2), **derivatives and the gradient** to minimise the loss (Ch. 3), the **mean, variance and correlation** to describe and evaluate the fit (Ch. 5), and the idea of **sampling error** to remember that the slope is an estimate (Ch. 6). These same tools sit underneath logistic regression, decision trees and deep learning.

ម៉ូដែលតូចមួយនេះបានប្រើគ្រប់ជំពូក៖ **វ៉ិចទ័រ និងម៉ាទ្រីស** ដើម្បីផ្ទុកទិន្នន័យ **ដេរីវេ និងក្រាដ្យង់** ដើម្បីបន្ថយកំហុស **មធ្យមភាគ វ៉ារ្យង់ និងសហសម្ព័ន្ធ** ដើម្បីពិពណ៌នា និងវាយតម្លៃ និងគំនិតនៃ **កំហុសសំណាក**។ ឧបករណ៍ដដែលទាំងនេះស្ថិតនៅពីក្រោម logistic regression, decision trees និង deep learning។

## Exercises 7

លំហាត់ ៧

1. Using $\hat{y} = 40.54 + 5.348x$, predict the score for 3 hours and for 12 hours. Why should you be careful with the 12-hour prediction?
   ព្យាករណ៍ពិន្ទុសម្រាប់ ៣ ម៉ោង និង ១២ ម៉ោង។ ហេតុអ្វីត្រូវប្រុងប្រយ័ត្នជាមួយ ១២ ម៉ោង?

2. Rerun the gradient descent listing with `lr = 0.05`, then with `lr = 0.03`. What happens in each case?
   ដំណើរការឡើងវិញជាមួយអត្រារៀនខុសៗគ្នា។ តើមានអ្វីកើតឡើង?

3. A model has $R^2 = 0.40$. Explain in one sentence what this means for a manager.
   ពន្យល់អត្ថន័យនៃ $R^2 = 0.40$ ក្នុងប្រយោគមួយ។

4. Split the 40 students into 30 for training and 10 for testing with `train_test_split`, then report the test RMSE.
   បំបែកទិន្នន័យជាសំណុំបង្វឹក និងតេស្ត ហើយរាយការណ៍ RMSE លើសំណុំតេស្ត។

5. Show that the gradient of $\text{MSE} = \frac{1}{n}\sum (y_i - b - m x_i)^2$ with respect to $b$ is $-\frac{2}{n}\sum (y_i - \hat{y}_i)$.
   បង្ហាញក្រាដ្យង់នៃ MSE ធៀបនឹង $b$។

# APPENDIX A · ANSWERS TO EXERCISES

## ឧបសម្ព័ន្ធ ក · ចម្លើយលំហាត់

Short answers are given for checking your work. Numbers were verified in Python. ចម្លើយខ្លីសម្រាប់ផ្ទៀងផ្ទាត់ការងាររបស់អ្នក។ លេខទាំងអស់ត្រូវបានផ្ទៀងផ្ទាត់ក្នុង Python។

### Chapter 1

1. $\sum_{i=1}^{5} 3i$.
2. $\bar{x} = 20/4 = 5$; `np.mean([2, 5, 5, 8])` returns `5.0`.
3. $3 + (-2) = 1$.
4. $2{,}000{,}000 \times 1.03^{15} \approx 3{,}115{,}935$ people.
5. House prices are right-skewed; a log scale stops a few very expensive houses from squashing every other point into a corner, and makes percentage changes look equal.

### Chapter 2

1. $\|\mathbf{u}\| = \sqrt{1+4+4} = 3$; unit vector $(1/3, -2/3, 2/3)$.
2. $(3)(-4) + (4)(3) = 0$, so the angle is $90°$.
3. $AB$ is $3 \times 4$. $BA$ is not defined, because $B$ has 4 columns but $A$ has 3 rows.
4. Determinant $= 4 - 2 = 2$; inverse $= \begin{pmatrix} 0.5 & -1 \\ -0.5 & 2 \end{pmatrix}$.
5. Coffee 4,000 riel, cake 3,500 riel.

### Chapter 3

1. $f'(x) = 15x^2 - 8x$.
2. $g'(x) = 6x\, e^{3x^2}$.
3. $\partial f/\partial x = 2xy$, $\partial f/\partial y = x^2 + 6y$; $\nabla f(1,2) = (4, 13)$.
4. $w_2$ is multiplied by $1 - 0.4 \times 6 = -1.4$ each step, so it flips sign and grows: $-2.8, 3.92, -5.49, \ldots$ The learning rate is too large for the steep direction, and the method diverges. $w_1$ still converges because $1 - 0.4 \times 2 = 0.2$.
5. $f'(x) = 2x - 6 = 0$ gives $x = 3$, with minimum value $f(3) = 1$.

### Chapter 4

1. $P = 13/52 + 4/52 - 1/52 = 16/52 \approx 0.308$.
2. $P(D \mid +) = 0.095/(0.095 + 0.045) \approx 0.679$. When the disease is more common, a positive test is much more convincing.

3. $X \sim \text{Binomial}(8, 0.25)$: $E[X] = 2$; $P(X \geq 6) \approx 0.0042$.
4. $P(X > 40) = P(Z > 2) \approx 0.0228$, about 2.3% of deliveries.
5. For example `np.random.default_rng(0).integers(0, 2, 10_000).mean()` gives a value close to 0.5.

### Chapter 5

1. Mean $40/7 \approx 5.71$, median 7, mode 7.
2. $\bar{x} = 5$, $\sum (x_i - \bar{x})^2 = 32$, $s^2 = 32/7 \approx 4.57$, $s \approx 2.14$.
3. The mean moves from 68.53 to 69.29; the median moves from 67.5 to 68.0. The mean changes more.
4. For example, the number of motorbikes and the number of phone shops in a district are correlated because both grow with population, not because one causes the other.
5. $r \approx 0.775$.

### Chapter 6

1. $SE = 12/\sqrt{36} = 2$; for $n = 144$, $SE = 1$.
2. $18.2 \pm 2.064 \times 2.5/5 = 18.2 \pm 1.03$, so $(17.17, 19.23)$ hours.
3. If there were truly no effect, we would see a result at least this extreme about 30% of the time, so the data give no real evidence against $H_0$.
4. With $n = 5$ the sample means are more spread out ($SE \approx 4.98/\sqrt{5} \approx 2.2$) and the histogram is still visibly skewed to the right.
5. Random assignment makes the two groups alike in every other way, so a difference in time-on-page can be attributed to the design and not to who happened to see it.

### Chapter 7

1. 3 hours: $\approx 56.6$. 12 hours: $\approx 104.7$, which is impossible for a score out of 100; the data only cover 1 to 10 hours, so this is unsafe **extrapolation**.
2. Both diverge: with `lr = 0.05` the weights blow up within about 30 epochs, and with `lr = 0.03` within about 230. With unscaled features, 0.01 is near the largest stable rate.
3. "The model explains about 40% of the differences in the outcome; 60% comes from other factors it does not include."
4. With `train_test_split(..., test_size=10, random_state=0)` the test RMSE is about 6.2 points (training slope 5.45). Your number will differ with another random split.
5. $\partial / \partial b$ of $(y_i - b - m x_i)^2$ is $-2(y_i - b - m x_i)$; averaging over $i$ gives $-\frac{2}{n}\sum (y_i - \hat{y}_i)$.

# APPENDIX B · PYTHON SETUP AND CHEAT SHEET

## ឧបសម្ព័ន្ធ ខ · ការដំឡើង Python និងសន្លឹកជំនួយ

### Option 1: Google Colab (no installation) មិនចាំបាច់ដំឡើង

Open `colab.research.google.com`, sign in with a Google account and create a new notebook. NumPy, pandas, SciPy, Matplotlib and scikit-learn are already installed.

> បើក `colab.research.google.com` ចូលដោយគណនី Google ហើយបង្កើត notebook ថ្មី។ បណ្ណាល័យទាំងអស់ដែលប្រើក្នុងសៀវភៅនេះ បានដំឡើងរួចជាស្រេច។

### Option 2: Your own computer លើកុំព្យូទ័ររបស់អ្នក

Install Python 3.10 or newer from `python.org`, then in a terminal run:

```
python -m pip install numpy pandas scipy matplotlib scikit-learn jupyter
jupyter notebook
```

The table below collects the functions used in this book [14, 5, 15].

| Task | Python | កិច្ចការ |
|---|---|---|
| Create an array | `np.array([1, 2, 3])` | បង្កើតអារេ |
| Sum, mean, std | `x.sum(), x.mean(), x.std(ddof=1)` | ផលបូក មធ្យមភាគ គម្លាតស្តង់ដារ |
| Dot product / matrix product | `a @ b` | ផលគុណស្កាលែ / ម៉ាទ្រីស |
| Vector length | `np.linalg.norm(a)` | ប្រវែងវ៉ិចទ័រ |
| Transpose, inverse | `A.T, np.linalg.inv(A)` | ម៉ាទ្រីសឆ្លាស់ និងច្រាស |
| Solve $A\mathbf{x} = \mathbf{b}$ | `np.linalg.solve(A, b)` | ដោះស្រាយប្រព័ន្ធ |
| Random numbers | `rng = np.random.default_rng(42)` | លេខចៃដន្យ |
| Read a CSV file | `pd.read_csv("file.csv")` | អានឯកសារ CSV |
| Summary statistics | `df.describe()` | ស្ថិតិសង្ខេប |
| Correlation matrix | `df.corr()` | ម៉ាទ្រីសសហសម្ព័ន្ធ |
| Normal probabilities | `stats.norm(mu, sigma).cdf(x)` | ប្រូបាបនរម៉ាល់ |
| Two-sample t-test | `stats.ttest_ind(a, b, equal_var=False)` | តេស្ត t សំណាកពីរ |
| Linear regression | `LinearRegression().fit(X, y)` | តំរែតំរង់លីនេអ៊ែរ |
| Line plot / histogram | `plt.plot(x, y)`, `plt.hist(x)` | ក្រាហ្វិកខ្សែ / អ៊ីស្តូក្រាម |

# APPENDIX C · ENGLISH–KHMER GLOSSARY

## ឧបសម្ព័ន្ធ គ · សទ្ទានុក្រម អង់គ្លេស–ខ្មែរ

| English | ខ្មែរ | Ch. | English | ខ្មែរ | Ch. |
|---|---|---|---|---|---|
| **A/B test** | តេស្ត A/B | 6 | logarithm | លោការីត | 1 |
| **Bayes' theorem** | ទ្រឹស្តីបទបាយេស | 4 | loss function | អនុគមន៍ខាតបង់ | 7 |
| **binomial distribution** | ចែកចាយទ្វេធា | 4 | matrix | ម៉ាទ្រីស | 2 |
| **chain rule** | វិធានខ្សែសង្វាក់ | 3 | mean | មធ្យមភាគ | 1, 5 |
| **conditional probability** | ប្រូបាបមានលក្ខខណ្ឌ | 4 | mean squared error | កំហុសការ៉េមធ្យម | 7 |
| **confidence interval** | ចន្លោះទំនុកចិត្ត | 6 | median | មេដ្យាន | 5 |
| **correlation** | សហសម្ព័ន្ធ | 5 | mode | ម៉ូត | 5 |
| **covariance** | កូវ៉ារ្យង់ | 5 | norm (length) | ណម (ប្រវែង) | 2 |
| **dataset** | សំណុំទិន្នន័យ | 1 | normal distribution | ចែកចាយនរម៉ាល់ | 4 |
| **derivative** | ដេរីវេ | 3 | null hypothesis | សម្មតិកម្មសូន្យ | 6 |
| **determinant** | ដេទែមីណង់ | 2 | outlier | តម្លៃជ្រុល | 5 |
| **dot product** | ផលគុណស្កាលែ | 2 | partial derivative | ដេរីវេដោយផ្នែក | 3 |
| **event** | ព្រឹត្តិការណ៍ | 4 | population | សកលស្ថិតិ | 6 |
| **expected value** | សង្ឃឹមគណិត | 4 | probability | ប្រូបាប | 4 |
| **exponential function** | អនុគមន៍អិចស្ប៉ូណង់ស្យែល | 1 | random variable | អថេរចៃដន្យ | 4 |
| **feature** | លក្ខណៈ | 1 | residual | សំណល់ | 7 |
| **function** | អនុគមន៍ | 1 | sample | សំណាក | 6 |
| **gradient** | ក្រាដ្យង់ | 3 | scalar | ស្កាលែ | 2 |
| **gradient descent** | ការចុះតាមក្រាដ្យង់ | 3, 7 | set | សំណុំ | 1 |
| **hypothesis test** | តេស្តសម្មតិកម្ម | 6 | standard deviation | គម្លាតស្តង់ដារ | 4, 5 |
| **identity matrix** | ម៉ាទ្រីសឯកតា | 2 | standard error | កំហុសស្តង់ដារ | 6 |
| **independent events** | ព្រឹត្តិការណ៍ឯករាជ្យ | 4 | summation | ផលបូក | 1 |
| **inverse matrix** | ម៉ាទ្រីសច្រាស | 2 | transpose | ម៉ាទ្រីសឆ្លាស់ | 2 |
| **learning rate** | អត្រារៀន | 3 | variance | វ៉ារ្យង់ | 4, 5 |
| **linear regression** | តំរែតំរង់លីនេអ៊ែរ | 7 | vector | វ៉ិចទ័រ | 2 |

# REFERENCES

## ឯកសារយោង

Numbers match the citations in the text. All books listed are good next steps for further study. លេខត្រូវគ្នានឹងការដកស្រង់ក្នុងអត្ថបទ។ សៀវភៅទាំងអស់ជាជំហានបន្ទាប់ដ៏ល្អសម្រាប់ការសិក្សាបន្ថែម។


[1] Deisenroth, M. P., Faisal, A. A., & Ong, C. S. (2020). *Mathematics for Machine Learning*. Cambridge University Press. https://mml-book.github.io

[2] Stewart, J. (2015). *Calculus: Early Transcendentals* (8th ed.). Cengage Learning.

[3] Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*, Chapters 2–4. MIT Press. https://www.deeplearningbook.org

[4] Strang, G. (2023). *Introduction to Linear Algebra* (6th ed.). Wellesley-Cambridge Press.

[5] Harris, C. R., Millman, K. J., van der Walt, S. J., et al. (2020). Array programming with NumPy. *Nature*, 585, 357–362.

[6] Ruder, S. (2016). An overview of gradient descent optimization algorithms. *arXiv preprint* arXiv:1609.04747.

[7] Blitzstein, J. K., & Hwang, J. (2019). *Introduction to Probability* (2nd ed.). CRC Press.

[8] Wasserman, L. (2004). *All of Statistics: A Concise Course in Statistical Inference*. Springer.

[9] Virtanen, P., Gommers, R., Oliphant, T. E., et al. (2020). SciPy 1.0: Fundamental algorithms for scientific computing in Python. *Nature Methods*, 17, 261–272.

[10] Bruce, P., Bruce, A., & Gedeck, P. (2020). *Practical Statistics for Data Scientists* (2nd ed.). O'Reilly Media.

[11] McKinney, W. (2022). *Python for Data Analysis* (3rd ed.). O'Reilly Media.

[12] James, G., Witten, D., Hastie, T., Tibshirani, R., & Taylor, J. (2023). *An Introduction to Statistical Learning with Applications in Python*. Springer. https://www.statlearning.com

[13] Pedregosa, F., Varoquaux, G., Gramfort, A., et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.

[14] VanderPlas, J. (2022). *Python Data Science Handbook* (2nd ed.). O'Reilly Media.

[15] Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. *Computing in Science & Engineering*, 9(3), 90–95.


Software documentation: numpy.org/doc · pandas.pydata.org/docs · docs.scipy.org · matplotlib.org · scikit-learn.org